Avaluació d'arquitectures de Deep Learning per al Reconeixement d'Activitats Humanes (HAR) mitjançant sensors inercials

Gerard Vidal Casasayas

Pattern Recognition and Computer Vision in Applied Sciences

Màster en Ciència de Dades

Nom del Tutor/a del TF:
Joaquín Torres Sospedra

Nom del de/la PRA:
David Masip Rodo

Gener 2025

Universitat Oberta de Catalunya

Aquesta obra està subjecta a una llicència de Reconeixement-NoComercial-SenseObraDerivada
https://creativecommons.org/licenses/by-nc/3.0/es/

Fitxa del Treball Final

Títol del treball:	Avaluació d'arquitectures de Deep Learning per al Reconeixement d'Activitats Humanes (HAR) mitjançant sensors inercials
Nom de l'autor/a:	Gerard Vidal Casasayas
Nom del Tutor/a del TF:	Joaquín Torres Sospedra
Nom del de/la PRA:	David Masip Rodo
Data de lliurament:	Gener 2025
Titulació o programa:	Màster en Ciència de Dades
Àrea del treball final:	Pattern Recognition and Computer Vision in Applied Sciences
Idioma del treball:	Català
Paraules clau:	HAR, Deep Learning, DeepConvLSTM, Sensors Inercials, Generalització, Sensor Fusion

Resum del treball

El reconeixement d'activitats humanes (HAR) mitjançant sensors inercials afronta el repte crític de la generalització: aconseguir que els models funcionin amb precisió sobre usuaris nous no vistos durant l'entrenament (*cross-user*). Aquest Treball Final de Màster presenta una anàlisi comparativa rigorosa entre aproximacions clàssiques (*Random Forest*), xarxes convolucionals (CNN) i arquitectures híbrides (*DeepConvLSTM*). Utilitzant un conjunt de dades públic amb 23 participants i fusió de sensors (Smartphone i Smartwatch), s'ha aplicat un protocol de validació *Leave-One-Subject-Out* (LOSO). Els resultats demostren la superioritat del model híbrid, que assoleix una exactitud del 80.82% i aconsegueix identificar eficaçment transicions complexes com els girs, superant les limitacions dels models que no processen l'evolució temporal gràcies a l'ús de memòria recurrent i a una estratègia de pesos per classe. Aquesta recerca confirma la viabilitat de solucions de monitoratge de salut robustes i accessibles.

Abstract

Human Activity Recognition (HAR) using inertial sensors faces the critical challenge of generalization: ensuring models perform correctly on new users not seen during training (cross-user scenarios). This Master's Thesis presents a rigorous comparative analysis between classic approaches (Random Forest), Convolutional Neural Networks (CNN), and hybrid architectures (DeepConvLSTM). Using a public dataset with 23 participants and sensor fusion (Smartphone and Smartwatch), a Leave-One-Subject-Out (LOSO) validation protocol was applied. Results demonstrate the superiority of the hybrid model, achieving an accuracy of 80.82%. Thanks to its recurrent memory and a class-weighting strategy, the model effectively identifies complex transitions such as turning movements, overcoming the limitations of models that lack temporal context. This research confirms the viability of robust and accessible health monitoring solutions.

Índex

1 Introducció **9**
1.1 Context i justificació del treball . . . 9
1.2 Objectius del treball . . . 9
1.3 Impacte en sostenibilitat, ètic-social i de diversitat . . . 10
1.3.1 Sostenibilitat . . . 10
1.3.2 Ètic i social . . . 10
1.3.3 Diversitat i drets humans . . . 10
1.4 Enfocament i mètode seguit . . . 11
1.5 Planificació del treball . . . 12
1.6 Breu sumari de productes obtinguts . . . 13
1.7 Breu descripció dels altres capítols de la memòria . . . 13

2 Estat de l'art **15**
2.1 Models i metodologies en HAR . . . 15
2.2 Conjunts de dades en HAR . . . 18
2.3 Reptes actuals: la generalització com a problema central . . . 19
2.3.1 Generalització en HAR . . . 19
2.4 Conclusions i plantejament del treball . . . 20

3 Metodologia i Implementació **22**
3.1 Descripció del Dataset i Entorn Experimental . . . 22
3.2 Pipeline de Preprocessament de Dades . . . 23
3.3 Processament i Fusió de Dades . . . 23
3.3.1 Identificació i Aparellament d'Arxius . . . 24
3.3.2 Fusió i Sincronització de Sensors . . . 24
3.3.3 Unificació i Codificació d'Etiquetes . . . 25
3.3.4 Segmentació en finestres . . . 26
3.3.5 Generació del Dataset: Tècnica de la Finestra Lliscant . . . 26
3.3.6 Anàlisi de la Distribució de Classes i Desbalanceig . . . 27
3.4 Definició del Baseline: Random Forest . . . 28
3.4.1 Enginyeria de Característiques (Feature Engineering 3D → 2D) . . . 28
3.4.2 Configuració del Model i Validació . . . 29
3.5 Implementació de Deep Learning . . . 30
3.5.1 Preprocessament Específic per a Deep Learning . . . 30
3.5.2 Arquitectura 1: CNN Standard (Baseline de Deep Learning) . . . 31

3.5.3 Disseny de l'Arquitectura . . . 31
3.5.4 Estratègia d'Entrenament Dinàmica . . . 32
3.5.5 Arquitectura 2: DeepConvLSTM (Híbrid CNN + Recurrent) . . . 32
3.5.6 Disseny de l'Arquitectura Híbrida . . . 33
3.5.7 Implementació de l'Entrenament i Gestió del Desbalanceig . . . 35
3.6 Estratègia d'Avaluació Experimental . . . 36
3.6.1 Protocol de Validació: Leave-One-Subject-Out (LOSO) . . . 36

4 Resultats Experimentals 38
4.1 Anàlisi del Baseline: Random Forest . . . 38
4.1.1 Rendiment Global i Eficiència . . . 38
4.1.2 Anàlisi d'Errors: Matriu de Confusió . . . 38
4.2 Anàlisi de l'Arquitectura CNN . . . 40
4.2.1 Rendiment Global: El Dilema de la Localitat . . . 40
4.2.2 Matriu de Confusió i Límits de la Convolució . . . 40
4.3 Anàlisi de l'Arquitectura Híbrida (DeepConvLSTM) . . . 41
4.3.1 Rendiment Global i Robustesa . . . 42
4.3.2 Impacte dels Pesos Manuals: El cas del 'Turning' . . . 42
4.3.3 Matriu de Confusió Final . . . 43
4.4 Comparativa Global i Discussió . . . 43

5 Conclusions i treballs futurs 45
5.1 Conclusions del treball . . . 45
5.2 Reflexió sobre l'assoliment dels objectius . . . 46
5.3 Anàlisi del seguiment de la planificació . . . 46
5.4 Avaluació de l'impacte . . . 47
5.5 Línies de treball futur . . . 47

6 Glossari 48

Índex de figures

1.1 Planificació temporal del TFM per fases (setmanes). 13

2.1 Flux de treball estàndard per implementar una aplicació HAR. 15

3.1 Diagrama del flux de dades. El procés culmina en la generació d'un Tensor 3D comú, que posteriorment s'adapta segons els requisits de cada model. 23
3.2 Diagrama de l'arquitectura CNN. L'ús de tres blocs amb profunditat creixent permet extreure característiques jeràrquiques. El Global Average Pooling final sintetitza la informació temporal abans de la classificació. 32
3.3 Diagrama del model DeepConvLSTM. Les capes convolucionals (blau) extreuen característiques visuals que són processades seqüencialment per les capes recurrents (lila). 33

4.1 Matriu de confusió normalitzada del model Random Forest. S'observa una incapacitat sistemàtica per distingir activitats amb estadístics similars però dinàmiques temporals oposades. 39
4.2 Matriu de confusió de la CNN Standard (valors absoluts). La classe Walking (907 encerts) segueix absorbint gran part dels errors de Turning (140 confusions). 41
4.3 Matriu de confusió de la DeepConvLSTM (valors absoluts). Es redueix la dispersió en la classe Turning (116 encerts vs 82 de la CNN) i millora la distinció Seated/Standing. 43

Índex de taules

3.1 Fragment de les dades crues (truncades a 4 decimals). **Nota:** Aquesta mateixa estructura de 8 columnes (sensors inercials + temps + etiqueta) es repeteix idènticament per als fitxers del Smartphone (SP) i del Smartwatch (SW). 23
3.2 Evolució de la distribució de classes abans i després de la segmentació. 28
3.3 Configuració dels pesos manuals per combatre el desbalanceig. 36

4.1 Resultats agregats del protocol LOSO per al Baseline (Random Forest). 39
4.2 Informe de classificació detallat per a la CNN. Destaquen l'alt rendiment en Walking i la persistent dificultat en Turning. 40
4.3 Informe de classificació de la DeepConvLSTM. La sensibilitat en Turning i Seated millora substancialment respecte als models anteriors. 42
4.4 Comparativa final del rendiment. La columna d'Accuracy (Acc.) inclou la mitjana i la desviació estàndard (±) del protocol LOSO. La DeepConvLSTM presenta la menor desviació (±6.92%), confirmant-se com el model més robust i estable entre diferents usuaris. 44

Capítol 1

Introducció

1.1 Context i justificació del treball

El reconeixement d'activitat humana (Human Activity Recognition, HAR) és un àmbit de recerca orientat a identificar les accions o els estats d'una persona a partir de dades procedents de sensors. Els enfocaments més habituals es basen en la recopilació de dades mitjançant acceleròmetres i giroscopis. Aquests sensors, integrats en telèfons i rellotges intel·ligents, permeten captar informació de moviment de manera contínua i poc intrusiva, i s'han consolidat com una alternativa assequible als sistemes més especialitzats. Aquesta accessibilitat ha obert la porta a aplicacions en àmbits com la salut, la rehabilitació, l'esport i l'assistència a la vida quotidiana [6].

Tot i els avenços recents, diversos estudis mostren que els models de HAR, tant basats en tècniques de *machine learning* com en arquitectures de *deep learning*, aconsegueixen bons resultats quan s'avaluen amb dades dels mateixos participants amb què han estat entrenats [2]. Tanmateix, el rendiment es redueix de manera notable quan s'apliquen a individus nous. Aquest fenomen és conegut com *overfitting*: el model s'ajusta massa als patrons específics dels usuaris coneguts i no és capaç de generalitzar adequadament. En el camp del HAR, aquesta limitació rep el nom de problema *cross-user* i constitueix un dels principals obstacles per a la seva aplicació en condicions reals [4].

En aquest treball es proposa una avaluació sistemàtica d'arquitectures de *deep learning* aplicades a dades recollides amb telèfons i rellotges intel·ligents. Per a dur a terme l'estudi, s'emprarà un conjunt de dades públic disponible a Zenodo [9], que inclou mesures d'acceleròmetre i giroscopi capturades simultàniament des d'un telèfon intel·ligent i un rellotge intel·ligent en 23 participants mentre realitzen activitats quotidianes. L'ús d'aquest dataset permet garantir transparència, reproductibilitat i comparabilitat amb estudis previs [10].

1.2 Objectius del treball

L'objectiu principal és detectar el model de deep learning que ofereix el millor rendiment en el reconeixement d'activitats humanes amb dades de telèfon i rellotge intel·ligent, posant el focus en la seva capacitat de generalització.

A partir d'aquest objectiu general, es defineixen els següents objectius específics:

- **Revisió d'estudis previs**: analitzar la literatura existent i treballs relacionats amb datasets similars per comprendre les metodologies utilitzades, els reptes oberts i les possibles estratègies de millora.
- **Avaluació de models i protocols**: implementar i entrenar diferents arquitectures de deep learning i analitzar-ne el rendiment sota diversos esquemes de validació utilitzant el conjunt de dades públic disponible a Zenodo [9].
- **Anàlisi de l'estratègia de fusió**: estudiar l'impacte d'utilitzar dades combinades de smartphone i smartwatch (*Sensor Fusion*) en la precisió del reconeixement d'activitats complexes.
- **Identificació de limitacions i línies futures**: descriure els punts febles del treball i plantejar possibles millores o extensions de recerca.

1.3 Impacte en sostenibilitat, ètic-social i de diversitat

1.3.1 Sostenibilitat

El treball aprofita sensors ja integrats en dispositius quotidians (telèfons i rellotges intel·ligents), evitant la necessitat d'infraestructures costoses o equipament addicional. Això redueix l'impacte ambiental i fomenta un ús més eficient dels recursos. Cal, però, tenir en compte el consum energètic associat a l'entrenament de models de *deep learning*, que contribueix a la petjada de carboni.

1.3.2 Ètic i social

La recerca té un impacte positiu en salut i benestar, ja que, entre d'altres coses, podria contribuir a sistemes de monitoratge i assistència que permetin a persones grans viure soles amb més seguretat. Segons l'Organització Mundial de la Salut, l'any 2050 hi haurà més de 2.1 bilions de persones majors de 60 anys, fet que accentua la necessitat de solucions accessibles per a la cura i la prevenció [15].

Alhora, el desenvolupament d'aquests sistemes comporta riscos en matèria de privacitat de dades, ja que requereixen captar informació personal de moviment i activitat. En aquest treball, aquest aspecte es té en compte utilitzant conjunts de dades públics i anonimitzats.

1.3.3 Diversitat i drets humans

El conjunt de dades inclou 23 participants amb una distribució de 13 homes i 10 dones, així com variabilitat en edats, alçades i pesos [9]. Aquesta heterogeneïtat permet avaluar els models en perfils diferents i redueix el risc de biaixos cap a un únic grup. Tot i això, la mostra no inclou persones de més de 70 anys, que són precisament les que podrien beneficiar-se més d'aplicacions de reconeixement d'activitats en l'àmbit de la salut i l'assistència. Per aquest motiu, és important reconèixer la limitació i fomentar en futurs estudis la incorporació de

poblacions més grans i amb condicions diverses, per garantir que els sistemes desenvolupats siguin aplicables i útils per a tota la societat.

A més, aquest treball s'alinea amb els Objectius de Desenvolupament Sostenible de les Nacions Unides, en especial amb l'ODS 3 (Salut i benestar) i l'ODS 10 (Reducció de les desigualtats). El desenvolupament d'eines de monitoratge accessibles pot contribuir a una millor prevenció i seguiment de l'activitat física, especialment en poblacions vulnerables i en persones grans.

1.4 Enfocament i mètode seguit

Per abordar el problema del reconeixement d'activitats amb dispositius portables, es poden contemplar diverses estratègies de recerca, cadascuna amb avantatges i limitacions pròpies. En el plantejament inicial del treball es van valorar diferents vies:

- **Desenvolupar una aplicació**: crear una app de salut que monitoritzi pacients grans a casa o una eina d'entrenament esportiu personalitzat. Aquesta via tindria un impacte directe i aplicacions pràctiques, però requereix competències que queden fora de l'abast del TFM.

- **Explorar nous enfocaments metodològics**: plantejar arquitectures innovadores de *deep learning* (per exemple, models basats en *Transformers* o mecanismes d'atenció complexos). Tot i que això podria aportar novetat científica, implica una inversió elevada en disseny i experimentació i no garanteix resultats dins del temps limitat d'un TFM.

- **Fer una anàlisi comparativa de models existents**: utilitzar arquitectures ja consolidades en la literatura i aplicar-les de manera crítica a un nou escenari experimental, posant el focus en reptes concrets com la generalització *cross-user* i la comparació entre dispositius (telèfon, rellotge i combinació).

Davant d'aquestes opcions, s'ha optat per l'anàlisi comparativa de models existents, amb èmfasi en la seva capacitat de generalització *cross-user*. Aquesta via ofereix un bon equilibri entre viabilitat, rellevància científica i capacitat de contribució original.

1.5 Planificació del treball

Recursos

Dispositius: ordinador personal, telèfon i rellotge intel·ligent.
Dades: Aquest treball empra el conjunt de dades públic, disponible a Zenodo [9] i descrit a la literatura. [10]. El dataset inclou 23 participants amb registres simultanis de smartphone i smartwatch durant cinc activitats quotidianes: estar assegut, aixecar-se, caminar, girar-se i asseure's.

Planificació

El desenvolupament del treball es divideix en sis fases, alineades amb el procés habitual de recerca en aprenentatge automàtic:

M1. Proposta. Delimitació del tema, justificació de la seva rellevància i motivació personal. Definició dels objectius principals i secundaris, metodologia prevista i planificació inicial del projecte.

M2. Revisió de l'estat de l'art. Anàlisi de literatura científica sobre HAR amb sensors inercials, identificació de reptes oberts i identificació de metodologies i arquitectures basades en estudis previs.

M3. Recol·lecció i tractament de dades. Preparació i segmentació del conjunt de dades públic [9], definició de l'estratègia experimental i normalització de les sèries temporals per a l'entrenament.

M4. Implementació dels models. Configuració i entrenament de diferents arquitectures de *deep learning* utilitzades habitualment en la literatura. Definició dels protocols de validació i les condicions d'entrenament necessàries per garantir la comparabilitat i la robustesa dels resultats.

M5. Experimentació i anàlisi de resultats. Comparació del rendiment dels models; interpretació dels resultats i detecció de limitacions.

M6. Documentació i presentació. Redacció progressiva de la memòria, elaboració del material audiovisual i preparació de la defensa oral del treball.

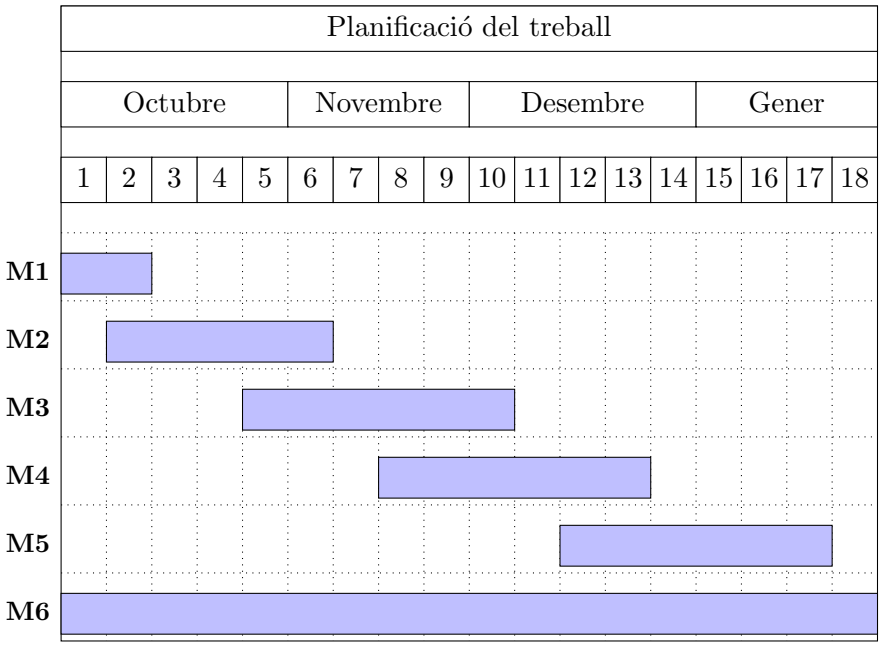

Figura 1.1: Planificació temporal del TFM per fases (setmanes).

1.6 Breu sumari de productes obtinguts

Com a resultat d'aquest treball de recerca, s'han generat els següents productes tangibles i intel·lectuals:

- **Codi de Preprocessament i Modelatge:** Un *notebook* integral executat a Google Colab que centralitza tot el flux de treball: des de la ingesta i sincronització de dades inercials (fusió de sensors) fins a la generació de tensors 3D preparats per a l'entrenament.
- **Arquitectures de Deep Learning Implementades:** La codificació i ajust d'hiperparàmetres de tres models distinctius per a HAR: un model base (*Random Forest*), una Xarxa Neuronal Convolucional (CNN) i una arquitectura híbrida (*DeepConvLSTM*) amb mecanismes de ponderació de classes.
- **Resultats Experimentals Validats:** Un estudi comparatiu rigorós basat en el protocol *Leave-One-Subject-Out* (LOSO), generant mètriques de rendiment (Accuracy, F1-Score) i matrius de confusió que quantifiquen la capacitat de generalització dels models davant usuaris no vistos.
- **Memòria del Projecte:** Aquest document, que recull l'estat de l'art, la justificació metodològica, l'anàlisi de resultats i les conclusions derivades de l'experimentació.

1.7 Breu descripció dels altres capítols de la memòria

La present memòria s'estructura en cinc capítols que guien el lector des del context teòric fins a les conclusions finals:

- **Capítol 2: Estat de l'Art.** Revisa la literatura existent sobre el reconeixement d'activitats humanes (HAR), analitzant l'evolució des dels mètodes clàssics fins al *Deep Learning*. S'hi discuteixen les problemàtiques actuals, sent el principal obstacle, la generalització *cross-user*.

- **Capítol 3: Metodologia i Implementació.** Detalla el disseny experimental: la descripció del dataset (23 subjectes, fusió Mòbil+Rellotge), el pipeline de preprocessament (finestres lliscants, normalització), i l'arquitectura interna dels models desenvolupats (Random Forest, CNN i DeepConvLSTM), així com l'estratègia d'entrenament.

- **Capítol 4: Resultats Experimentals.** Presenta l'avaluació quantitativa i qualitativa dels models. S'hi analitzen les matrius de confusió i les taules de sensibilitat per classe, comparant el rendiment del Baseline amb les arquitectures profundes sota el protocol de validació LOSO.

- **Capítol 5: Conclusions i Treballs Futurs.** Sintetitza les troballes principals, reflexiona sobre l'assoliment dels objectius inicials i l'impacte del treball, i proposa noves línies de recerca per continuar millorant la robustesa dels sistemes HAR.

Capítol 2

Estat de l'art

2.1 Models i metodologies en HAR

Els sistemes de reconeixement d'activitats humanes (HAR) basats en sensors inercials segueixen habitualment un flux de treball estructurat que comprèn quatre etapes principals: (i) identificació del dispositiu utilitzat per capturar el moviment, com ara telèfons o rellotges intel·ligents, (ii) captura i processament de les dades, incloent-hi l'eliminació de soroll i l'extracció de característiques rellevants, (iii) selecció i entrenament d'un model d'aprenentatge automàtic a partir de les dades processades, i (iv) avaluació del model per determinar-ne el rendiment i la capacitat de generalització [6].

Aquest flux es pot implementar seguint dos grans enfocaments metodològics. Els models de *machine learning* clàssic (CML) requereixen calcular prèviament valors estadístics del senyal —com la mitjana o la variabilitat— abans d'entrenar el model de classificació. En canvi, els models de *deep learning* (DL) poden aprendre directament de les sèries temporals originals dels sensors, identificant automàticament els patrons més rellevants per distingir cada activitat [7, 6].

En el context actual, els sensors inercials —especialment l'acceleròmetre i el giroscopi integrats als *smartphones* i rellotges intel·ligents— constitueixen la font de dades més habitual en reconeixement d'activitats. Diversos estudis han mostrat que la seva combinació permet capturar tant la intensitat com la direcció del moviment, millorant la precisió del model respecte a l'ús d'un únic sensor [7, 13]. Abans de l'entrenament, les dades s'acostumen a segmentar en finestres temporals fixes i a normalitzar per reduir diferències entre usuaris o dispositius, especialment en escenaris de generalització *cross-user*. Aquestes finestres serveixen com a entrada per a models d'aprenentatge supervisat que identifiquen patrons d'activitat com caminar, seure o pujar escales.

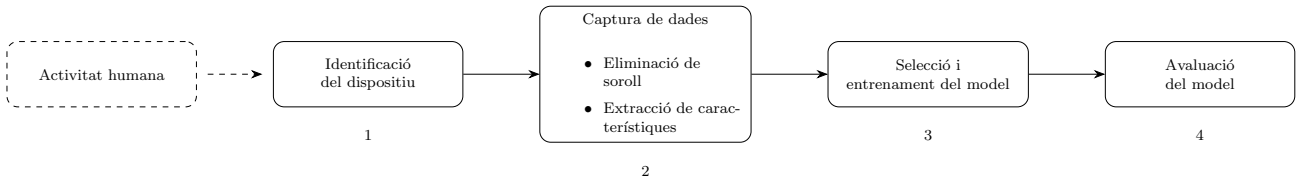

Figura 2.1: Flux de treball estàndard per implementar una aplicació HAR.

Models de Machine Learning clàssic

Els primers sistemes de reconeixement d'activitats basats en sensors inercials es van fonamentar en tècniques de *machine learning* clàssic. En aquests enfocaments, el model no treballava directament amb les dades dels sensors, sinó amb un conjunt de valors numèrics derivats d'aquestes dades —com la mitjana, la variabilitat o la potència en determinades bandes de freqüència— que descrivien el moviment observat. Aquests valors, coneguts com a *features*, es feien servir com a entrada per a classificadors supervisats com els k-Nearest Neighbours (kNN), els *Support Vector Machines* (SVM) o els *Random Forests* [2, 6]. Aquests mètodes resultaven especialment adequats en conjunts de dades petits o quan hi havia coneixement expert sobre el tipus de moviment analitzat, i continuen oferint rendiments competitius en escenaris ben controlats [7]. Tot i la seva simplicitat, aquests models presenten diversos avantatges. Requereixen menys dades i capacitat de càlcul que les arquitectures de *deep learning*, són més ràpids d'entrenar i permeten interpretar amb facilitat quines variables influeixen en la classificació [2]. Tanmateix, la seva dependència del procés manual de definició de *features* limita la capacitat de detectar patrons complexos o variacions entre usuaris. Això fa que tendeixin a sobreajustar-se al conjunt de dades d'entrenament i mostrin un rendiment inferior en entorns reals o en situacions de generalització *cross-user* [7].

Un dels estudis més representatius d'aquesta etapa és el d'Ignatov i Strijov (2015), que van dissenyar un sistema de reconeixement d'activitats utilitzant únicament les dades d'un acceleròmetre integrat en un telèfon intel·ligent. El conjunt de dades emprat recollia registres de moviment de tretze participants mentre realitzaven sis activitats quotidianes —caminar, córrer, pujar i baixar escales, seure i estar dret—. Cada registre corresponia a una seqüència temporal de mesures d'acceleració en tres direccions (eixos X, Y i Z).

Els autors van proposar un mètode per dividir aquestes sèries temporals en segments que representessin cicles de moviment, assumint que activitats com caminar o córrer presenten patrons repetitius. Un cop segmentades i filtrades les dades, cada finestra es va classificar mitjançant l'algorisme k-Nearest Neighbours (kNN), que assigna una activitat al segment comparant-lo amb els més semblants del conjunt d'entrenament.

L'experiment va assolir una precisió global del 96 % en la identificació de les activitats, superant una xarxa neuronal multicapa entrenada sobre les mateixes dades. Els autors van concloure que, amb una segmentació acurada i un conjunt de dades ben controlat, els models de machine learning clàssic poden assolir un rendiment molt elevat i fins i tot comparable al de tècniques més complexes [8].

Un altre estudi representatiu d'aquest període és el de Bayat et al 2014, que analitza el reconeixement d'activitats utilitzant únicament l'acceleròmetre d'un telèfon intel·ligent [3]. Els autors van recollir dades de quatre participants mentre realitzaven sis activitats quotidianes —caminar lent, caminar ràpid, córrer, pujar escales, baixar escales i dansa aeròbica—. Les dades es van segmentar en finestres de 128 mostres i es van calcular 24 característiques estadístiques i de freqüència, incloent la mitjana, la desviació estàndard, el valor pic-a-pic i mesures de variabilitat del ritme de pas.

A partir d'aquest conjunt de característiques, es van entrenar diversos classificadors supervisats, com ara SVM, Random Forest, LogitBoost i un perceptró multicapa de poca profunditat. Els resultats van mostrar que els mètodes basats en arbres i les xarxes neuronals superficials

obtenien els millors rendiments, assolint una precisió aproximada del 89%–91% tant quan el dispositiu es portava a la mà com a la butxaca. Els autors també van observar que combinar múltiples classificadors podia millorar lleugerament el rendiment global.

Tot i que incorpora una xarxa neuronal superficial, aquesta continua depenent d'un procés explícit de *feature engineering*, motiu pel qual s'emmarca dins dels enfocaments tradicionals previs a l'adopció generalitzada de models de *deep learning* basats en dades en brut.

En conjunt, els enfocaments de *machine learning* clàssic han estat fonamentals en les primeres etapes del reconeixement d'activitats amb sensors inercials. La seva eficàcia en escenaris controlats, juntament amb la simplicitat computacional i interpretabilitat, els fa encara útils en aplicacions amb recursos limitats o conjunts de dades reduïts. Tanmateix, la dependència d'una enginyeria manual de característiques i les dificultats per generalitzar entre usuaris i contextos han impulsat la transició cap a models capaços d'aprendre representacions directament a partir de les dades en brut. Aquest canvi ha donat lloc a l'adopció creixent de tècniques de *deep learning*, que han esdevingut l'estàndard actual en HAR i es presenten a la secció següent.

Models de *Deep Learning*

L'aparició del *deep learning* ha suposat un canvi important en el reconeixement d'activitats humanes (HAR) basat en sensors inercials. A diferència dels mètodes clàssics, que requereixen definir manualment característiques a partir dels senyals, els models profunds poden aprendre directament de les dades en brut dels acceleròmetres i giroscopis [17, 14].

Dins d'aquest camp destaquen tres arquitectures principals.

Convolutional Neural Networks (CNN): Aquestes xarxes processen els senyals en petites finestres temporals i identifiquen patrons locals característics del moviment. Per exemple, poden detectar la forma recurrent que presenta el senyal d'acceleració quan una persona fa un pas caminant. Això les fa especialment útils per capturar patrons repetitius i estructures curtes en dades temporals.

Long Short-Term Memory Networks (LSTM). Les LSTM són un tipus de xarxes neuronals recurrents (RNN) dissenyades per processar seqüències de dades i "recordar" informació del passat recent. Això és útil en reconeixement d'activitats, perquè el moviment d'una persona no depèn només d'un instant puntual, sinó de com canvia el senyal al llarg del temps. Per exemple, per distingir entre "asseure's" i "aixecar-se" cal tenir en compte la direcció del moviment: en un cas el cos baixa i en l'altre puja. Una finestra curta pot veure valors similars en tots dos casos, però una LSTM pot diferenciar-los perquè té memòria del que ha passat just abans.

Arquitectures híbrides: Molts treballs recents combinen CNN i LSTM per aprofitar els seus avantatges complementaris: les CNN detecten patrons locals del moviment i les LSTM modelen la seva evolució al llarg del temps. Aquest enfocament ha demostrat millores clares respecte als mètodes basats en *feature engineering* i classificadors tradicionals, especialment en condicions realistes amb dades provinents de dispositius mòbils [17, 14].

Un dels primers treballs que va demostrar clarament el potencial del *deep learning* per al reconeixement d'activitats amb sensors inercials és el de Yang al 2015 [17]. Els autors proposen utilitzar una xarxa neuronal convolucional (CNN) aplicada directament sobre sèries temporals multicanal (múltiples sensorsi eixos per mostra) procedents de diversos sensors corporals.

La idea clau és evitar l'ús de característiques manualment dissenyades, que fins aleshores dominaven la literatura en HAR. En lloc d'això, la CNN aprèn automàticament patrons discriminatius a partir del senyal brut. La xarxa examina com el moviment canvia al llarg del temps dins d'una finestra de dades, detectant petits patrons repetits o transicions pròpies de cada activitat, i després combina la informació vinguda de tots els sensors per prendre la decisió.

Els resultats mostren que aquest model supera mètodes clàssics com SVM o k-NN, així com models de *deep learning* no convolucionals com *Deep Belief Networks*. Això evidencia que les CNN són especialment eficients en captar patrons recurrrents del senyal, proporcionant representacions més robustes i específiques a la tasca.

En resum, l'estudi introdueix una aportació fonamental: demostrar que és possible fer HAR de forma efectiva sense *feature engineering*, obrint el camí a arquitectures profundes que treballen directament amb dades de sensors.

Per una altra banda, l'estudi d'Ordóñez i Roggen [14] representa un pas endavant clau; tot i que les CNN temporals ja havien demostrat ser eficaces en extreure patrons locals del senyal brut, aquest treball mostra que, en activitats on l'ordre i l'evolució temporal són especialment rellevants, combinar CNN amb xarxes LSTM millora significativament el rendiment.

L'arquitectura proposada, anomenada *DeepConvLSTM*, consisteix en una seqüència de capes convolucionals que capturen patrons locals de moviment, seguida de capes LSTM que modelen la progressió temporal d'aquestes característiques. Això permet que el model distingeixi activitats amb dinàmiques similars però seqüències oposades (p. ex., *asseure's* vs. *aixecar-se*), fet que una CNN pura pot perdre.

Per validar el model, els autors utilitzen dos conjunts de dades molt coneguts en HAR. El primer, Opportunity, prové d'un entorn domèstic: persones fent activitats quotidianes com obrir portes, agafar objectes o moure's per una cuina, mentre porten sensors. Per una altra banda, Skoda, recull moviments repetitius en una fàbrica d'automòbils, amb un treballador fent tasques de muntatge de manera estructurada i repetida.

Aquests dos escenaris són molt diferents: el primer és variat i imprevisible, i el segon és repetitiu i ordenat. El fet que el model funcioni bé en ambdós casos demostra que és capaç de reconèixer activitats tant en situacions de la vida diària com en contextos industrials.

2.2 Conjunts de dades en HAR

La recerca en reconeixement d'activitats humanes (HAR) ha evolucionat en gran part gràcies a la disponibilitat de conjunts de dades públics. Aquests datasets permeten comparar mètodes i avaluar la seva capacitat de generalització en situacions realistes.

Els primers conjunts de dades, com UCI-HAR i WISDM, es caracteritzen per entorns controlats, pocs participants i sensors únicament en smartphones. Tot i el seu valor històric i la seva simplicitat, presenten limitacions importants: poca variabilitat entre usuaris, escenaris poc realistes i absència de dispositius múltiples, fet que facilita la classificació però no reflecteix

l'ús quotidià dels sistemes portables actuals.

Posteriorment, datasets més complexos com Opportunity i Skoda van incorporar sensors múltiples col·locats en diferents parts del cos i activitats més riques. Aquestes bases van permetre avançar en models capaços de capturar comportaments variats, però segueixen tenint restriccions pel que fa a diversitat d'usuaris i configuracions de dispositius.

En aquest treball s'utilitza el conjunt de dades públic de Matey-Sanz et al. [9], que combina registres simultanis de smartphone i smartwatch en 23 participants realitzant activitats quotidianes. A diferència de datasets clàssics centrats en un únic dispositiu o en entorns molt controlats, aquest recull dades reals amb variabilitat entre usuaris i sensors portats de forma natural, fet que permet avaluar de manera més rigorosa la capacitat de generalització dels models.

2.3 Reptes actuals: la generalització com a problema central

Els sistemes de HAR basats en sensors inercials funcionen molt bé quan s'entrenen i s'avaluen en condicions similars. Tanmateix, el rendiment cau sovint quan canvien les persones, els dispositius o el context d'ús. Aquest fenomen, conegut com a *desajust de domini* (*domain shift*), és avui el repte central de la disciplina: el model ha d'aprendre patrons d'activitat útils més enllà del conjunt i de les condicions amb què es va entrenar [6, 2]. En la pràctica, aquest desajust adopta tres formes molt comunes: (i) **variabilitat entre persones** (*cross-user*), perquè cada individu es mou diferent; (ii) **heterogeneïtat de dispositius** (*cross-device*), atès que canvien fabricants, sensors i rangs de mesura; i (iii) **canvis de posició/orientació** (*cross-position*), degut a que la col·locació del sensor altera el senyal capturat. A aquests factors s'hi sumen soroll, activitats compostes i condicions d'ús no controlades, que accentuen la bretxa entre entrenament i aplicació real [6, 4].

2.3.1 Generalització en HAR

El repte clau és la **generalització**: que el model funcioni amb usuaris nous, dispositius diferents o posicions del sensor que no ha vist. Les revisions recents coincideixen que aquesta manca de generalització és un obstacle central per a implementar HAR fiable en entorns reals [6, 2, 4]. A continuació, es presenten tres estudis que il·lustren estratègies complementàries davant d'aquest problema.

Adaptació temporal del domini per generalitzar entre usuaris (cross-user)

Ye et al. [18] aborda directament el cross-user. La idea és senzilla: tot i que cada persona camina o es mou amb un estil propi, les fases d'una activitat (p. ex., aixecar el peu, avançar-lo, recol·locar-lo) són compartides. El seu mètode (DTSDA) fa dues coses: (a) segmenta les seqüències per detectar aquestes sub-etapes comunes i (b) aplica entrenament adversarial, on un submodel intenta identificar l'usuari d'origen del senyal mentre la resta del model intenta impedir-ho, obligant així la xarxa a aprendre representacions neutrals respecte a la identitat.

En conjunt, el sistema es veu forçat a centrar-se en patrons de moviment generals i no en trets idiosincràtics de cada individu, millorant la robustesa en escenaris cross-user.

Robustesa a canvis de posició del dispositiu (cross-position)

En l'ús quotidià, la posició del dispositiu pot variar (butxaca, mà, canell esquerre o dret). Si el model depèn massa de la ubicació exacta del sensor, el rendiment es degrada substancialment quan aquesta posició canvia. Un estudi recent proposa una arquitectura dissenyada per mantenir una precisió elevada fins i tot en aquestes situacions [11]. L'enfocament consisteix a centrar-se en patrons de moviment que es mantenen estables independentment de la col·locació del dispositiu. Per aconseguir-ho, el model combina: (i) convolucions capaces de capturar micro-patrons locals del senyal, com els impulsos característics d'un pas; (ii) un mòdul temporal que modela com aquests patrons s'encadenen i evolucionen en el temps; i (iii) un mecanisme d'atenció que assigna més pes als segments més informatius de la seqüència.

Els autors avaluen el model en conjunts de dades públics amb sensors col·locats en múltiples parts del cos, incloent Opportunity, entre d'altres. Els resultats mostren valors F1 compresos aproximadament entre el 86% i el 96% segons el conjunt de dades, així com una reducció significativa de la pèrdua de rendiment quan el dispositiu es prova en posicions noves, en comparació amb arquitectures profundes convencionals. Això suggereix que aprendre patrons temporals compartits entre posicions contribueix a desenvolupar sistemes HAR més robustos en escenaris d'ús real.

Generalització multiescenari

Un treball clau per entendre la dificultat de generalitzar en entorns reals és el de Napoli et al. [12]. Els autors no proposen una nova arquitectura, sinó que se centren a resoldre un problema previ: la falta d'estàndards. Van crear DAGHAR, una plataforma que unifica diversos conjunts de dades públics per eliminar diferències tècniques (com freqüències de mostreig o unitats dispars) que dificultaven les comparacions justes.

Un cop unificades les dades, van posar a prova diversos models clàssics i van veure que, malgrat netejar els formats, els models continuaven fallant estrepitosament quan canviaven d'usuari. La seva conclusió reforça la tesi d'aquest TFM: el problema no és el format de les dades, sinó la falta de capacitat dels models simples per capturar la complexitat del moviment humà. Això justifica la necessitat d'arquitectures avançades amb memòria temporal (com la DeepConvLSTM) i de protocols de validació robustos (LOSO) com els que aquí s'avaluen.

2.4 Conclusions i plantejament del treball

L'anàlisi de l'estat de l'art evidencia una transició tecnològica clara en el camp del reconeixement d'activitats humanes (HAR): els mètodes de *machine learning* clàssic, tot i ser eficients i interpretables, estan cedint pas a arquitectures de *deep learning* —especialment CNN i LSTM— capaces d'extreure patrons complexos directament de les dades inercials en brut [17, 14].

No obstant això, la literatura recent assenyala que l'obtenció d'una alta precisió en un conjunt de test estàtic ja no és suficient. El repte central s'ha desplaçat cap a la capacitat de **generalització** [6, 2]. Com s'ha discutit anteriorment, la variabilitat inherent a la forma de

moure's de cada persona (*cross-user*) o els canvis de context provoquen sovint una caiguda dràstica del rendiment quan els models s'enfronten a escenaris reals no vistos durant l'entrenament [12].

Partint d'aquest context, aquest Treball Final de Màster es fonamenta en la necessitat d'una avaluació metodològica rigorosa que vagi més enllà de la simple maximització de mètriques. La disponibilitat del conjunt de dades públic descrit a [10], ens proporciona un escenari ideal per a aquest propòsit: amb 23 participants i la captura simultània de *smartphone* i *smartwatch*, ofereix la diversitat necessària per posar a prova la robustesa dels models.

Per tant, la metodologia que es presenta al capítol següent es dissenya amb els objectius següents:

- Implementar un **flux de processament complet i robust**, des de la normalització i el finestratge de les dades inercials fins a l'avaluació final, assegurant que les dades d'entrada siguin consistents i de qualitat.
- Comparar el rendiment d'un enfocament de referència basat en ***machine learning* clàssic** (amb extracció manual de característiques estadístiques) enfront de models de ***deep learning*** (CNN i LSTM) que treballin amb el senyal en brut, seguint la línia de [17].
- Avaluar la capacitat de generalització mitjançant esquemes de validació estrictes, posant especial èmfasi en l'avaluació *cross-user* (deixant usuaris complets fora de l'entrenament) per simular un entorn d'aplicació real.

En definitiva, aquest treball busca aplicar les lliçons apreses en l'estat de l'art per construir un sistema HAR que no només sigui precís, sinó metodològicament sòlid i conscient dels reptes de generalització actuals.

Capítol 3

Metodologia i Implementació

En aquest capítol es detalla el disseny experimental i la implementació del sistema de reconeixement d'activitats humanes (HAR). El desenvolupament s'ha estructurat seguint un *pipeline* estructurat i pensat per transformar els senyals inercials bruts en tensors preparats per als models d'aprenentatge profund. L'objectiu ha estat crear un procés coherent que prioritzi la reproductibilitat dels experiments i justifiqui cada decisió de disseny.

3.1 Descripció del Dataset i Entorn Experimental

S'ha utilitzat el conjunt de dades públic descrit a [10], disponible al repositori Zenodo. Aquest dataset conté registres inercials de **23 subjectes** heterogenis realitzant 5 activitats de la vida diària: *Walking* (Caminar), *Turning* (Girar-se), *Standing Up* (Aixecar-se), *Sitting Down* (Asseure's) i *Seated* (Estar assegut).

L'entorn de desenvolupament s'ha fonamentat en el llenguatge de programació **Python** (versió 3.10), executat sobre la plataforma al núvol **Google Colab**. Per optimitzar el temps de còmput, especialment durant l'entrenament de la xarxa DeepConvLSTM, s'ha utilitzat una instància amb acceleració per maquinari mitjançant GPU (NVIDIA T4).

L'ecosistema de llibreries utilitzat s'estructura en tres blocs funcionals:

- **Càlcul i Manipulació de Dades:** *NumPy* per a operacions d'àlgebra lineal i gestió de tensors, i *Pandas* per al processament d'estructures de dades tabulars i sèries temporals.
- **Visualització i Anàlisi:** *Matplotlib* i *Seaborn* per a la generació de gràfiques exploratòries i matrius de confusió.
- **Modelatge i Avaluació:** *Scikit-Learn* per a la implementació del baseline (Random Forest), preprocessament (StandardScaler) i càlcul de mètriques; i *TensorFlow* amb la interfície *Keras* per al disseny i entrenament dels models d'aprenentatge profund.

x_acc	y_acc	z_acc	x_gyro	y_gyro	z_gyro	timestamp	label
-4.1602	-1.1829	-8.9907	0.0028	-0.0139	-0.0321	1657533977813	SEATED
-4.1841	-1.1901	-9.0146	0.0071	-0.0114	-0.0229	1657533977864	SEATED
-4.1961	-1.2308	-9.0505	0.0101	-0.0126	-0.0125	1657533977864	SEATED
-4.2442	-1.2547	-9.1055	0.0113	-0.0139	-0.0003	1657533977865	SEATED
-4.2323	-1.2882	-9.1534	0.0113	-0.0169	0.0131	1657533977865	SEATED
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Taula 3.1: Fragment de les dades crues (truncades a 4 decimals). **Nota:** Aquesta mateixa estructura de 8 columnes (sensors inercials + temps + etiqueta) es repeteix idènticament per als fitxers del Smartphone (SP) i del Smartwatch (SW).

3.2 Pipeline de Preprocessament de Dades

El processament de les dades fins a la generació dels vectors d'entrada segueix un flux seqüencial dissenyat per garantir la integritat del senyal, tal com es representa a la Figura 3.1.

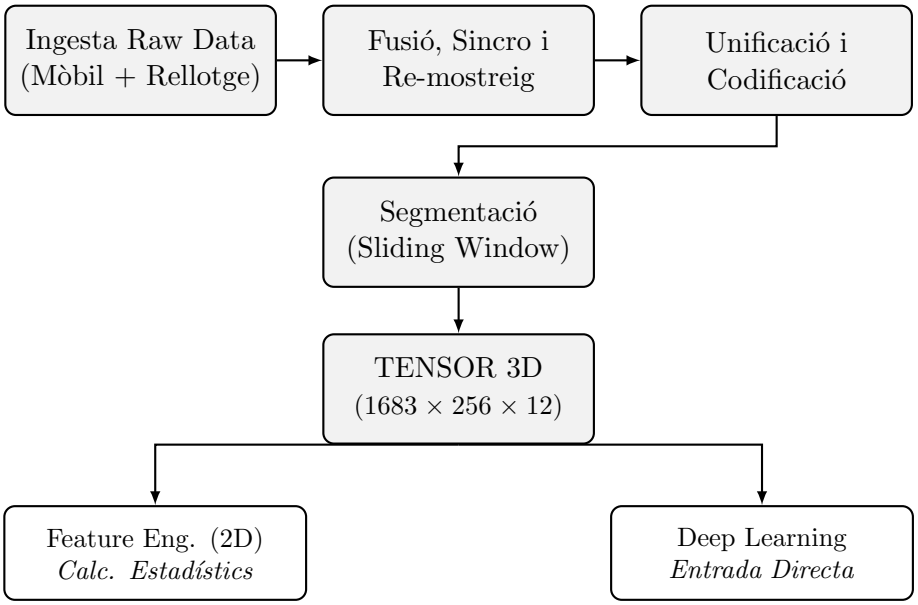

Figura 3.1: Diagrama del flux de dades. El procés culmina en la generació d'un Tensor 3D comú, que posteriorment s'adapta segons els requisits de cada model.

3.3 Processament i Fusió de Dades

El flux de treball s'inicia amb l'adquisició i preparació de les dades brutes. Tal com s'il·lustra a la Figura 3.1, abans de poder entrenar cap model, és necessari transformar els fitxers origi-

nals fragmentats en una estructura unificada i coherent. Aquest procés s'ha dividit en etapes seqüencials.

3.3.1 Identificació i Aparellament d'Arxius

En aquesta primera fase, el sistema recorre les carpetes de tots els subjectes i localitza els fitxers corresponents a la mateixa sessió. Per exemple, per a l'experiment número 3 del Subjecte 1, el sistema busca la parella d'arxius (CSV del mòbil i CSV del rellotge) i els carrega en memòria conjuntament.

L'objectiu d'aquesta etapa és garantir que tenim les dades completes dels dos sensors per a cada experiment abans de començar a processar-les.

3.3.2 Fusió i Sincronització de Sensors

Un cop les dades han estat ingerides, l'objectiu és combinar la informació del canell (rellotge) i del maluc (mòbil) en una única matriu temporal sincronitzada. El procediment implementat resol el repte de tenir freqüències de mostreig dispars mitjançant els següents passos:

1. **Identificació de l'Origen (Prefixos):** Tant el mòbil com el rellotge registren dades amb els mateixos noms de columna (ex: `acc_x`, `acc_y`). Si els ajuntéssim directament, seria impossible distingir quina acceleració pertany a quin dispositiu. Per solucionar-ho, s'ha aplicat un reanomenament sistemàtic abans de la fusió:
   - Dades del mòbil: s'afegeix el prefix `phone_` (ex: `phone_acc_x`).
   - Dades del rellotge: s'afegeix el prefix `watch_` (ex: `watch_acc_x`).
2. **Sincronització per Longitud Mínima:** S'ha observat que, tot i començar a gravar alhora, els fitxers d'una mateixa sessió poden tenir una diferència de poques mostres degut a la latència d'escriptura (ex: el mòbil té 1000 files i el rellotge 1005). Com que necessitem aparellar les dades fila a fila, s'ha optat per retallar l'excedent del fitxer més llarg fins a igualar la longitud del més curt. Això garanteix que no quedin espais buits a la matriu final.
3. **Unificació:** Un cop tenim les taules del mòbil i del rellotge alineades, es fusionen horitzontalment. El resultat d'aquesta operació és, per a cada sessió de gravació individual (en total 223), una matriu unificada on cada fila conté l'estat inercial complet de l'usuari en aquell instant. Posteriorment, aquestes sessions individuals s'emmagatzemen en una estructura de diccionari per ser processades en bloc.

   Justificació de la Fusió (Early Fusion): S'ha decidit unificar les dades del rellotge i del mòbil en un únic fitxer abans d'entrenar, en lloc de crear models separats per a cada dispositiu. El motiu és senzill: el moviment humà és coordinat. Quan caminem, movem el braç (rellotge) i el maluc (mòbil) amb un ritme conjunt. Si ajuntem les dades des del principi (*Early Fusion*), el model pot aprendre aquesta relació entre extremitats. Fer-ho per separat implicaria perdre aquesta informació de coordinació, un fet que estudis com el d'Ordóñez et al. [14] ja han demostrat que empitjora els resultats.

3.3.3 Unificació i Codificació d'Etiquetes

Després de la fusió temporal, es va abordar la inconsistència inherent al *Ground Truth*. Atès que cada dispositiu registra la seva pròpia etiqueta de manera independent, es van detectar discrepàncies puntuals entre sensors per al mateix instant de temps t.

Un cas típic es produeix en les transicions ràpides: sovint, el Smartwatch encara indica "SEATED" mentre el Smartphone ja ha registrat el canvi a "WALKING". Davant d'aquesta contradicció, el sistema requereix un criteri determinista per establir l'etiqueta correcta.

Estratègia de Priorització Jeràrquica

Per resoldre aquestes ambigüitats, s'ha dissenyat una lògica de prioritat basada en la ubicació anatòmica i la fiabilitat biomecànica del sensor:

- **Font Primària (Smartphone):** S'estableix com a veritat prioritària. En estar ubicat a la butxaca, proper al centre de masses del cos, captura amb més fidelitat la dinàmica del tren inferior, que és la que defineix l'activitat de locomoció.
- **Font Secundària (Smartwatch):** En cas de conflicte (quan $y_{watch} \neq y_{phone}$), la seva etiqueta es descarta i se substitueix automàticament per la del Smartphone.

Aquesta decisió de disseny es fonamenta en l'evidència presentada per Cleland et al. [5], els quals demostren que la col·locació del sensor al maluc ofereix una precisió significativament superior en la classificació d'activitats de locomoció comparat amb la posició al canell, més subjecta a moviments espuris no relacionats amb la marxa.

Codificació Numèrica (Label Encoding)

Finalment, per preparar les dades per a l'entrenament (que requereix tensors numèrics per al càlcul de la pèrdua *Sparse Categorical Crossentropy*), s'ha transformat l'espai d'etiquetes categòriques en índexs enters:

- **0:** SEATED (Estar assegut)
- **1:** STANDING_UP (Aixecar-se)
- **2:** WALKING (Caminar)
- **3:** TURNING (Girar-se)
- **4:** SITTING_DOWN (Asseure's)

3.3.4 Segmentació en finestres

Un pas previ indispensable a la segmentació ha estat determinar la velocitat real de captura dels sensors. L'anàlisi dels registres temporals ha revelat que els dispositius capturen dades amb un interval mitjà de 10 ms. Això implica una freqüència de mostreig efectiva de **100 Hz** (és a dir, es registren 100 mesures per segon), una freqüència superior als 50 Hz habituals en datasets clàssics.

Aquest paràmetre ha estat determinant per definir la mida de la finestra temporal. S'ha pres com a referència l'estudi d'Anguita et al. [1], que estableix una durada física de **2.56 segons** per finestra. L'elecció d'aquest valor concret respon a un doble criteri:

(a) **Criteri Biomecànic:** Garanteix la captura d'almenys un cicle complet de locomoció (dues passes), fins i tot en persones amb cadència lenta, assegurant que la finestra contingui tota la informació necessària per identificar l'activitat.

(b) **Criteri Matemàtic:** Anguita treballava a 50 Hz, i 2.56 segons corresponen exactament a 128 mostres. El número 128 és una potència de dos (2^7), una propietat que optimitza certs càlculs d'algorismes de processament de senyal com la Transformada Ràpida de Fourier (FFT).

Adaptant aquests principis al nostre dataset de 100 Hz, s'han fixat els següents paràmetres:

- **Mida de la Finestra (W): 256 mostres.** En multiplicar la durada objectiu (2.56 s) per la nostra freqüència (100 Hz), obtenim exactament 256 mostres. Curiosament, aquest valor també és una potència de dos (2^8), mantenint l'eficiència computacional. A més, això implica que els nostres models treballaran amb el **doble de resolució temporal** que els estudis originals (256 punts per descriure el mateix gest que Anguita descrivia amb 128), permetent capturar matisos de moviment més subtils.
- **Solapament (*Overlap*): 50% (128 mostres).** S'ha aplicat un desplaçament de mitja finestra, de manera que cada nova finestra comparteix el 50% de les dades amb l'anterior. Aquesta estratègia té dues funcions clau:
  (a) **Invariància a la segmentació:** Evita que un esdeveniment puntual (com un impacte o un gir brusc) quedi tallat a la frontera entre dues finestres, assegurant que sempre aparegui sencer en alguna d'elles.
  (b) **Augment de Dades (Data Augmentation implícit):** En generar més finestres a partir de la mateixa seqüència temporal, incrementem el volum de dades disponibles per a l'entrenament. Cal destacar que aquesta és una primera fase d'augment estructural; posteriorment, s'aplicarà una segona fase d'augment sintètic (afegint soroll) exclusivament al conjunt d'entrenament.

3.3.5 Generació del Dataset: Tècnica de la Finestra Lliscant

Per transformar els registres continus en estructures aptes per a l'entrenament supervisat, s'ha implementat un algorisme de *Sliding Window* que genera tres estructures de dades sincronitzades: el tensor d'entrada (X), el vector d'etiquetes (y) i el vector de subjectes ($groups$).

Segmentació i Política de Residus

L'algorisme recorre cada sessió de gravació aplicant un pas de desplaçament de 128 mostres. Per garantir la integritat dimensional necessària per a les xarxes neuronals convolucionals (que requereixen entrades de mida fixa), s'ha adoptat una política estricta de **Drop Remainder**. Això implica que si la longitud total d'una sessió no és un múltiple exacte de la finestra, les mostres residuals finals (menys de 256) són descartades. Aquesta decisió prioritza la qualitat de les dades (evitant tècniques de *padding* artificial amb zeros) enfront de la quantitat.

Consolidació d'Etiquetes (Majority Voting)

Un repte inherent a la segmentació és que els models d'aprenentatge supervisat requereixen una única etiqueta de sortida (y) per a cada finestra d'entrada (X). Tanmateix, en un segment de 2.56 segons poden conviure mostres de dues activitats diferents (per exemple, durant una transició on l'usuari deixa de caminar per asseure's).

Per resoldre aquesta ambigüitat de manera robusta, s'ha implementat un mecanisme de **votació majoritària**. Aquest procés consisteix a calcular la moda estadística de les 256 etiquetes originals de la finestra: l'activitat que apareix amb més freqüència és la que s'assigna definitivament a tot el segment. Aquesta estratègia permet identificar l'activitat predominant i actua com un filtre de soroll, descartant etiquetes espúries o transicions molt breus que no representen l'acció principal.

Estructura Final del Tensor

El resultat final d'aquest procés és un tensor tridimensional X de dimensions $(1683, 256, 12)$, on:

- 1683: Nombre total de finestres generades.
- 256: Dimensió temporal (seqüència).
- 12: Dimensió espacial (canals dels sensors: acc/gyro $\times$ x/y/z $\times$ phone/watch).

Aquest tensor s'acompanya dels vectors y (etiquetes) i *groups* (identificadors d'usuari) per permetre la validació creuada LOSO.

3.3.6 Anàlisi de la Distribució de Classes i Desbalanceig

Un cop generat el tensor final X, és crític analitzar la distribució de les etiquetes resultants, ja que qualsevol biaix en les dades d'entrenament condicionarà el comportament del model.

L'anàlisi comparativa entre les mostres crues (abans de segmentar) i les finestres finals (després de segmentar) revela un fenomen de desbalanceig sever accentuat pel procés de finestratge, tal com es resumeix a la Taula 3.2.

Activitat	Mostres Crues (Raw)	Finestres Finals (Windows)	Impacte
WALKING	44.43%	**63.04%**	+18.61%
TURNING	20.16%	13.84%	-6.32%
STANDING UP	10.54%	10.16%	-0.38%
SITTING DOWN	12.27%	9.63%	-2.64%
SEATED	12.60%	**3.33%**	-9.27%

Taula 3.2: Evolució de la distribució de classes abans i després de la segmentació.

S'observa un predomini absolut de la classe **WALKING**, que passa de representar el 44.43% de les mostres originals a constituir el 63.04% del dataset final. Aquest fenomen s'explica per la naturalesa contínua de l'activitat: caminar genera seqüències llargues i ininterrompudes que produeixen moltes finestres vàlides.

En canvi, activitats estàtiques o de transició pateixen una reducció dràstica. El cas més notable és **SEATED**, que cau del 12.60% al 3.33%. Això es deu al fet que els períodes d'estar assegut sovint es troben a l'inici o al final de les sessions de gravació i, a causa de la política de *Drop Remainder*, moltes d'aquestes mostres queden descartades si no arriben a formar un bloc complet de 256 punts.

Aquest desbalanceig (il·lustrat a la Taula 3.2) planteja un repte important: si s'entrenés el model sense correccions, aquest podria assolir una *accuracy* enganyosament alta (aprox. 63,04%) simplement predint sempre 'WALKING' i ignorant les classes minoritàries.

Per mitigar aquest risc, es justifica la implementació de dues estratègies correctores que es detallaran a la secció d'Experimentació:

(a) L'ús de mètriques com l'**F1-Score** (Weighted) en lloc de l'Accuracy pura.

(b) L'aplicació de **Class Weights** (pesos de penalització) a la funció de pèrdua, forçant la xarxa neuronal a prestar més atenció als errors comesos en les classes minoritàries.

3.4 Definició del Baseline: Random Forest

Per establir un punt de referència sòlid (*Baseline*) que permeti quantificar les millores aportades per les arquitectures de Deep Learning, s'ha implementat un model clàssic basat en *Random Forest*. Aquest algorisme ha estat seleccionat per la seva robustesa davant del soroll i la seva capacitat d'interpretabilitat en problemes de classificació multiclase.

3.4.1 Enginyeria de Característiques (Feature Engineering 3D $\rightarrow$ 2D)

El tensor d'entrada té dimensions $(1683, 256, 12)$. La dimensió central (256) correspon a l'**eix temporal**: conté la seqüència ordenada de mostres que descriu com evoluciona el moviment segon a segon.

Els algorismes clàssics com el *Random Forest* no estan dissenyats per processar seqüències ni matrius 3D; requereixen una taula bidimensional simple on cada fila sigui un exemple i cada columna una dada fixa. Per adaptar-hi les nostres dades, és necessari **eliminar la dimensió temporal**.

Això s'ha aconseguit mitjançant una estratègia d'**agregació columnar independent**. La transformació s'aplica separadament a cadascun dels 12 canals del sensor (les columnes de la matriu). Per a un canal concret C_j, es prenen les seves 256 mostres temporals i es condensen en 4 valors estadístics, perdent la noció d'ordre però preservant la informació global de la distribució.

Concretament, per a cada finestra i i per a cada sensor j (on $j = 1..12$), s'extreure'n els següents descriptors:

(a) **Mitjana (μ):** Indica la tendència central del vector de 256 mostres. Útil per distingir postures estàtiques (ex: la gravetat constant en l'eix Y distingeix estar dret d'estar assegut).

(b) **Desviació Estàndard (σ):** Quantifica la dispersió o intensitat del moviment al llarg de la finestra. S'espera que sigui alta en activitats dinàmiques (*Walking*) i baixa en estàtiques.

(c) **Màxim (max):** El valor més alt assolit pel canal del sensor dins dels 2.56 segons.

(d) **Mínim (min):** El valor més assolit pel canal sensor dins dels 2.56 segons.

En resum, aquest procés transforma l'estructura de les dades dràsticament: passem de tenir un tensor tridimensional d'entrada $(1683, 256, 12)$ a obtenir una taula bidimensional final de $(1683, 48)$, resultat de concatenar els 4 descriptors estadístics per a cadascun dels 12 sensors.

3.4.2 Configuració del Model i Validació

S'ha utilitzat un classificador *Random Forest* amb la següent configuració d'hiperparàmetres:

- **Nombre d'estimadors:** 100 arbres. Segons l'estudi d'Oshiro et al. [16], aquest nombre representa un punt d'equilibri òptim on l'augment de precisió s'estabilitza i el cost computacional es manté controlat.
- **Reproductibilitat:** S'ha fixat la llavor aleatòria (*random_state=42*) per garantir que els resultats siguin idèntics en futures execucions.

Validació del Model

L'entrenament i avaluació del Random Forest s'ha realitzat seguint estrictament el protocol **Leave-One-Subject-Out (LOSO)** definit a la secció 3.6.

Per a cada iteració del LOSO, s'ha utilitzat l'objecte `LeaveOneGroupOut` de *Scikit-Learn* per gestionar automàticament la partició de subjectes, assegurant que les 48 característiques estadístiques d'entrenament i test pertanyin a individus completament disjunts.

3.5 Implementació de Deep Learning

A diferència del Baseline, que depenia d'una extracció manual de característiques, en aquesta fase s'ha implementat una arquitectura de *Deep Learning* dissenyada per aprendre patrons directament del senyal brut $(1683, 256, 12)$. La primera arquitectura proposada és una Xarxa Neuronal Convolucional (CNN) unidimensional, eficaç per detectar patrons locals (com pics o girs) independentment de la seva posició temporal en la finestra.

3.5.1 Preprocessament Específic per a Deep Learning

Abans d'alimentar la xarxa, s'han aplicat dues tècniques de preprocessament crítiques integrades dins del bucle de validació LOSO per garantir la robustesa i evitar el *Data Leakage*.

Normalització (Standard Scaling)

Les xarxes neuronals són altament sensibles a l'escala de les dades d'entrada. Per facilitar la convergència de l'algorisme d'optimització (Gradient Descent), s'ha aplicat una estandardització per forçar que les dades tinguin mitjana 0 i desviació estàndard 1:

$$x' = \frac{x - \mu_{train}}{\sigma_{train}} \tag{3.1}$$

És fonamental destacar que els paràmetres μ i σ s'han calculat exclusivament sobre el conjunt d'**entrenament** de cada iteració i s'han aplicat posteriorment als conjunts de validació i test. Això evita que informació estadística del subjecte de test çontamini"el model durant l'entrenament.

Data Augmentation (Injectat de Soroll Gaussià)

Donada la limitació en la quantitat de subjectes (Small Data), les xarxes profundes tendeixen a memoritzar les dades d'entrenament (*Overfitting*). Per mitigar-ho, s'ha implementat una tècnica d'augment de dades sintètic aplicada només al conjunt d'entrenament. Es duplica el nombre de mostres injectant soroll gaussià additiu a les dades originals:

$$X_{aug} = X_{train} + \mathcal{N}(0, 0.05) \tag{3.2}$$

Aquest soroll, amb una desviació de 0.05, simula petites variacions o vibracions en el sensor. Això força la xarxa a aprendre la "forma"estructural del moviment i no els valors numèrics exactes, millorant la capacitat de generalització davant nous usuaris.

3.5.2 Arquitectura 1: CNN Standard (Baseline de Deep Learning)

Per a la primera aproximació basada en Deep Learning, s'ha dissenyat una xarxa neuronal convolucional unidimensional (1D-CNN) completament supervisada. A diferència del Machine Learning clàssic (Random Forest), on les característiques s'han de definir manualment *a priori*, aquesta arquitectura té la capacitat d'aprendre automàticament els filtres òptims per discriminar activitats directament des del senyal brut.

L'arquitectura proposada (Figura 3.2) segueix un disseny jeràrquic de tres blocs en cascada. La intuïció darrere d'aquest disseny és la abstracció progressiva:

(a) Els primers blocs detecten micro-moviments simples (canvis bruscos d'acceleració, orientació).

(b) Els blocs profunds combinen aquests detalls per reconèixer patrons complexos de més llarga durada.

3.5.3 Disseny de l'Arquitectura

Els components clau que defineixen aquesta arquitectura i la seva funció biomecànica són:

Blocs d'Extracció de Característiques

El nucli de la xarxa està format per tres mòduls convolucionals. Cada mòdul aplica la següent seqüència d'operacions:

- **Convolució 1D (Feature Extraction):** S'utilitzen nuclis (*kernels*) de mida $k = 3$ que es desplacen al llarg de l'eix temporal. Aquestes operacions tracten els 12 sensors simultàniament com a canals de profunditat, aprenent les correlacions espacials entre el rellotge i el mòbil. La profunditat de la xarxa es duplica a cada bloc ($64 \rightarrow 128 \rightarrow 256$ filtres) per permetre una representació cada cop més rica del senyal.
- **Batch Normalization:** Just després de la convolució, es normalitzen les activacions per mantenir una mitjana propera a 0 i una variància d'1. Això mitiga el problema del *Covariate Shift* intern, fent la xarxa més robusta davant diferents intensitats de moviment entre subjectes i accelerant la convergència.
- **MaxPooling (Reducció Dimensional):** S'aplica un submostreig de factor 2. Això redueix la resolució temporal a la meitat a cada pas, filtrant el soroll d'alta freqüència i conservant només els pics d'activació més rellevants (els moments de màxima energia).

Classificació i Invariància Temporal (GAP)

Un punt crític del disseny és la transició entre l'extracció de característiques i la classificació final. En lloc d'utilitzar la clàssica operació d'aplanament (*Flatten*), s'ha optat pel **Global Average Pooling (GAP)**.

El GAP calcula la mitjana de cada mapa de característiques de l'últim bloc. Això aporta dos avantatges clau:

(a) **Invariància Temporal:** Al model no li importa en quin mil·lisegon exacte ocorre un pic d'acceleració, sinó la "presència global" d'aquest patró dins la finestra.

(b) **Regularització Estructural:** Redueix dràsticament la quantitat de pesos a entrenar, minimitzant el risc d'overfitting.

Finalment, un capçal dens (*Dense Layer*) de 128 neurones amb regularització *Dropout* (50%) processa aquest vector resumit per generar les probabilitats finals mitjançant una funció Softmax.

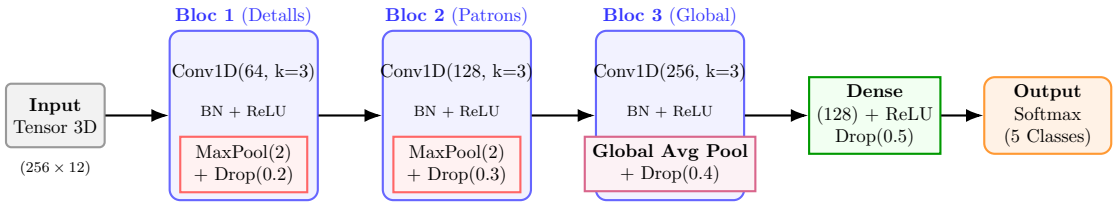

Figura 3.2: Diagrama de l'arquitectura CNN. L'ús de tres blocs amb profunditat creixent permet extreure característiques jeràrquiques. El Global Average Pooling final sintetitza la informació temporal abans de la classificació.

3.5.4 Estratègia d'Entrenament Dinàmica

L'entrenament s'ha gestionat mitjançant l'optimitzador **Adam** ($\alpha = 0.001$) i la funció de pèrdua *Sparse Categorical Crossentropy*. Donada la variabilitat del protocol LOSO (23 entrenaments diferents), s'ha implementat un sistema de control automàtic basat en un subconjunt de validació interna (15% dels subjectes d'entrenament):

- **Early Stopping:** Atura l'entrenament si la pèrdua en validació no millora durant 15 èpoques, restaurant els millors pesos. Això evita que la xarxa memoritzi soroll en lloc d'aprendre patrons generalitzables.
- **ReduceLROnPlateau:** Si l'error s'estanca durant 5 èpoques, la taxa d'aprenentatge es redueix a la meitat (factor 0.5), permetent un ajustament més fi en les fases finals de l'optimització.

3.5.5 Arquitectura 2: DeepConvLSTM (Híbrid CNN + Recurrent)

L'arquitectura CNN presentada anteriorment excel·leix en la detecció de patrons locals (com ara pics d'impacte sobtats). No obstant això, presenta una limitació estructural intrínseca: el seu *camp receptiu* està limitat per la mida del filtre o *kernel*. Això significa que la xarxa té dificultats per relacionar esdeveniments que estan molt separats en el

temps dins la mateixa finestra (dependències de llarg abast), ja que només "veu"petits fragments del senyal simultàniament.

Per superar aquesta limitació sense perdre la capacitat d'extracció de característiques de la CNN, s'ha implementat l'arquitectura 'DeepConvLSTM', basada en la proposta d'Ordóñez i Roggen [14].

Aquest model proposa un disseny en dues etapes diferenciades:

(a) **Extracció de Característiques (CNN):** Les primeres capes actuen com un filtre intel·ligent que processa el senyal brut i en redueix el soroll, generant una representació abstracta "frame a frame".

(b) **Modelització Temporal (LSTM):** Les característiques extretes s'introdueixen en capes recurrents que disposen de memòria. Això permet al sistema analitzar la seqüència completa i entendre l'evolució temporal de l'activitat (l'ordre dels fets), clau per distingir transicions complexes.

3.5.6 Disseny de l'Arquitectura Híbrida

El disseny implementat (il·lustrat a la Figura 3.3) presenta diferències significatives respecte a la CNN estàndard anterior per adaptar-se millor a la naturalesa seqüencial de les transicions.

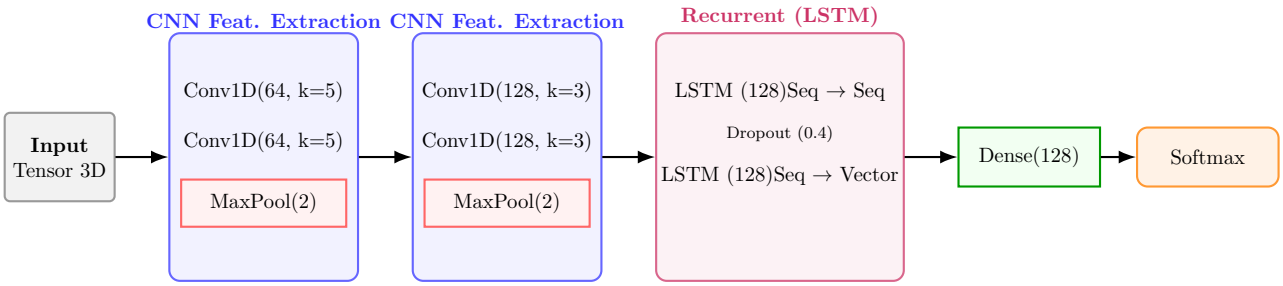

Figura 3.3: Diagrama del model DeepConvLSTM. Les capes convolucionals (blau) extreuen característiques visuals que són processades seqüencialment per les capes recurrents (lila).

Etapa 1: Extracció de Característiques (Bloc Convolucional)

La primera fase de la xarxa té la funció de processar el senyal brut per facilitar la feina a les capes posteriors. En aquesta arquitectura híbrida, el disseny presenta canvis estratègics clau respecte a la CNN estàndard:

- **Mida del Filtre ($k = 5$)** Un filtre (o *kernel*) actua com una finestra lliscant que analitza un petit segment temporal per detectar-hi patrons. Mentre que en la CNN pura s'utilitzava una finestra estreta ($k = 3$) per capturar detalls microscòpics, aquí s'ha ampliat a $k = 5$. En abastar més mostres simultàniament, el filtre esdevé menys sensible a les petites vibracions o 'soroll' instantani del sensor i se centra a extreure

la *tendència* estructural del moviment. Això és crucial per a l'arquitectura híbrida: volem lliurar a la capa LSTM una seqüència de característiques **neta i robusta**, sense les fluctuacions d'alta freqüència que podrien dificultar l'aprenentatge de les dependències temporals llargues.

- **Apilament de Capes (Layer Stacking):** S'apliquen dues capes convolucionals consecutives abans de cada reducció (*MaxPooling*). Això permet a la xarxa processar la informació en dos nivells de profunditat abans de resumir-la: la primera capa detecta formes simples i la segona combina aquestes formes per construir patrons més complexos. Aquest mecanisme millora la qualitat de les característiques extretes sense perdre resolució temporal prematurament.
- **Reducció (MaxPooling):** Finalment, s'aplica l'operació de *MaxPooling*, que redueix la dimensió temporal a la meitat quedant-se només amb els valors d'activació màxims. Això serveix per eliminar informació redundant i destacar només la presència o absència dels patrons rellevants.

Etapa 2: Modelització Temporal (Bloc Recurrent)

Les característiques extretes per la CNN entren al bloc recurrent com una seqüència de 64 passos temporals (resultat de les reduccions prèvies), on cada pas està representat per un vector de 128 atributs. Aquesta estructura representa una sola finestra.

L'objectiu d'aquesta etapa és transformar aquesta seqüència temporal en un únic vector de decisió final. Això s'aconsegueix mitjançant dues capes LSTM que operen de manera diferent sobre la dimensió temporal:

(a) **LSTM 1 (Seqüència a Seqüència):** La primera capa processa els 64 passos mantenint l'estructura temporal (`return_sequences=True`). A diferència de la CNN, on cada punt es processava de forma aïllada, aquí cada neurona actualitza el seu estat intern basant-se en el pas actual i en l'estat del pas anterior. **Resultat:** La sortida segueix sent una matriu de 64 passos, però ara cada vector conté informació çontextualitzada": sap què ha passat en els instants previs.

(b) **LSTM 2 (Seqüència a Vector):** La segona capa té la funció de 'col·lapsar' el temps (`return_sequences=False`). Recorre tota la seqüència contextualitzada de 64 passos acumulant informació, però descarta les sortides intermèdies i només emet l'estat final. **Resultat:** Obtenim un únic vector de 128 valors que resumeix la 'història' completa de la finestra de 2.56 segons. Aquest vector final conté la informació necessària per distingir l'ordre dels esdeveniments (per exemple, diferenciar l'acció d'asseure's de la d'aixecar-se).

Etapa 3: Classificació Final

Finalment, el vector de 128 característiques resultant de l'etapa recurrent es connecta a una capa completament connectada (*Dense Layer*) amb 5 neurones de sortida (una per a cada activitat).

Aquesta capa projecta l'espai de característiques latent sobre l'espai de classes. Per obtenir la predicció final, s'aplica la funció d'activació **Softmax**, que converteix les sortides numèriques en una distribució de probabilitat:

$$P(y = c|x) = \frac{e^{z_c}}{\sum_{j=1}^{C} e^{z_j}} \tag{3.3}$$

On z_c és la sortida bruta per a la classe c. La classe amb la probabilitat més alta és seleccionada com l'etiqueta predita per a la finestra analitzada.

3.5.7 Implementació de l'Entrenament i Gestió del Desbalanceig

Per a l'entrenament del model DeepConvLSTM, s'ha seguit un pipeline rigorós dissenyat per prevenir el *Data Leakage* i combatre el desbalanceig de classes. El procediment, integrat dins del bucle de validació creuada LOSO, consta de les següents etapes:

Protocol de Pre-processament en Bucle

A diferència de les aproximacions estàtiques, les transformacions de les dades s'apliquen dinàmicament a cada iteració del validació creuada per garantir la integritat experimental:

- **Normalització Aïllada:** L'escalat de les dades (*StandardScaler*) s'ajusta (*fit*) exclusivament amb el subconjunt d'entrenament de la iteració actual (X_{train}). Els paràmetres de mitjana i desviació obtinguts s'apliquen posteriorment al conjunt de test (X_{test}). Això garanteix que el model mai "vegiïnformació estadística del subjecte que ha de predir.
- **Data Augmentation (Soroll Gaussià):** Per millorar la capacitat de generalització i evitar l'overfitting en un model amb tants paràmetres, s'aplica una tècnica d'augmentació de dades només al conjunt d'entrenament. S'introdueix soroll gaussià aleatori ($\mu = 0, \sigma = 0.05$) a les finestres originals, duplicant efectivament el nombre de mostres disponibles per aprendre patrons robustos.

Estratègia de Ponderació de Classes (Class Weights)

Malgrat l'augmentació de dades, durant la fase experimental inicial es va detectar que el model tendia a convergir cap a una solució trivial: predir majoritàriament la classe dominant (*Walking*), ignorant les classes minoritàroes com *Turning*.

Per corregir aquest comportament, s'ha modificat la funció de pèrdua (*Weighted Categorical Cross-Entropy*) introduint un vector de **Pesos Manuals** (w_c). La funció de cost es defineix com:

$$Loss = -\sum_{c=1}^{C} w_c \cdot y_{real,c} \cdot \log(y_{pred,c}) \tag{3.4}$$

Els pesos s'han assignat manualment seguint una lògica de penalització inversa a la freqüència i proporcional a la importància biomecànica (veure Taula 3.3).

Classe	**Pes (w_c)**	**Justificació Tècnica**
TURNING (3)	**3.5**	Prioritat Màxima. Classe minoritària crítica. Es penalitza severament l'error.
SEATED (0)	2.5	Prioritat Alta. Evitar confusió amb Standing.
STANDING UP (1)	2.0	Prioritat Mitjana. Transició dinàmica.
SITTING DOWN (4)	1.5	Prioritat Mitjana-Baixa.
WALKING (2)	**0.9**	Relaxació. Classe dominant. Es redueix la seva influència.

Taula 3.3: Configuració dels pesos manuals per combatre el desbalanceig.

Aquesta estratègia, combinada amb els *callbacks* de control (Early Stopping i reducció del Learning Rate), força la xarxa a "arriscar-se"a predir girs, ja que el cost matemàtic d'ignorar-los és ara molt superior al cost de fallar una finestra de caminar.

3.6 Estratègia d'Avaluació Experimental

Per garantir que els resultats obtinguts siguin robustos i comparables, s'ha definit un protocol d'avaluació comú per a totes les arquitectures analitzades en aquest treball (tant per al Baseline com per als models de Deep Learning).

3.6.1 Protocol de Validació: Leave-One-Subject-Out (LOSO)

S'ha descartat l'ús de particions aleatòries simples (com el clàssic *train/test split* 80/20), ja que en dades biomètriques existeix una forta correlació entre les mostres d'un mateix individu. Si el model veiés com camina el "Subjecte 1"durant l'entrenament, el reconeixeria fàcilment al test, falsejant les mètriques de rendiment.

Per simular l'escenari d'aplicació real més exigent (un sistema que ha de funcionar correctament per a un usuari nou sense calibratge previ) s'ha implementat l'esquema **Leave-One-Subject-Out (LOSO)**. Aquest procediment iteratiu s'executa 23 vegades, seguint aquesta lògica:

(a) En cada iteració k, se selecciona un subjecte concret per actuar com a **conjunt de test** (l'usuari "desconegut").

(b) El model s'entrena des de zero utilitzant exclusivament les dades dels altres **22 subjectes**.

(c) S'avalua el model sobre el subjecte de test i es registra el rendiment.

El resultat final reportat correspon a la mitjana aritmètica d'aquestes 23 avaluacions independents, garantint que no hi ha hagut cap fuita d'informació (*Data Leakage*) entre usuaris.

Capítol 4

Resultats Experimentals

En aquest capítol es presenten els resultats obtinguts després d'executar el protocol de validació *Leave-One-Subject-Out* (LOSO) sobre les tres arquitectures proposades. L'anàlisi comença establint el rendiment base amb algorismes clàssics i progressa cap a les solucions de Deep Learning, per acabar amb una comparativa global.

4.1 Anàlisi del Baseline: Random Forest

El primer experiment avalua l'eficàcia de l'aproximació clàssica basada en *Feature Engineering* manual. En aquesta fase, els tensors 3D originals ($1683 \times 256 \times 12$) s'han col·lapsat en vectors de característiques estadístiques 2D (1683×48), eliminant la dimensió temporal per fer-les compatibles amb el classificador Random Forest.

4.1.1 Rendiment Global i Eficiència

La Taula 4.1 resumeix les mètriques quantitatives. El model assoleix una exactitud mitjana del **78.90%**, una xifra inicialment prometedora per a un algorisme que no processa el senyal brut. A més, destaca per la seva eficiència extrema: el protocol complet d'entrenament i validació s'ha executat en només 33.55 segons, confirmant la seva viabilitat per a maquinari de molt baix consum.

No obstant això, l'anàlisi de la variabilitat ($\pm 7.81\%$) alerta sobre problemes greus de generalització: mentre que en alguns subjectes el rendiment és excel·lent, arribant al 94%, en d'altres cau fins al 60%, demostrant una forta dependència de la biomecànica específica de l'usuari.

4.1.2 Anàlisi d'Errors: Matriu de Confusió

Per comprendre les causes de la inestabilitat, s'ha generat la matriu de confusió acumulada (Figura 4.1). Aquesta visualització revela les limitacions estructurals del model estadístic, exposant errors crítics que queden emmascarats per la mètrica d'Accuracy global.

Mètrica	Resultat Mitjà	Variabilitat (Std)
Accuracy (Global)	78.90%	±7.81%
F1-Score (Weighted)	76.08%	±8.00%

Taula 4.1: Resultats agregats del protocol LOSO per al Baseline (Random Forest).

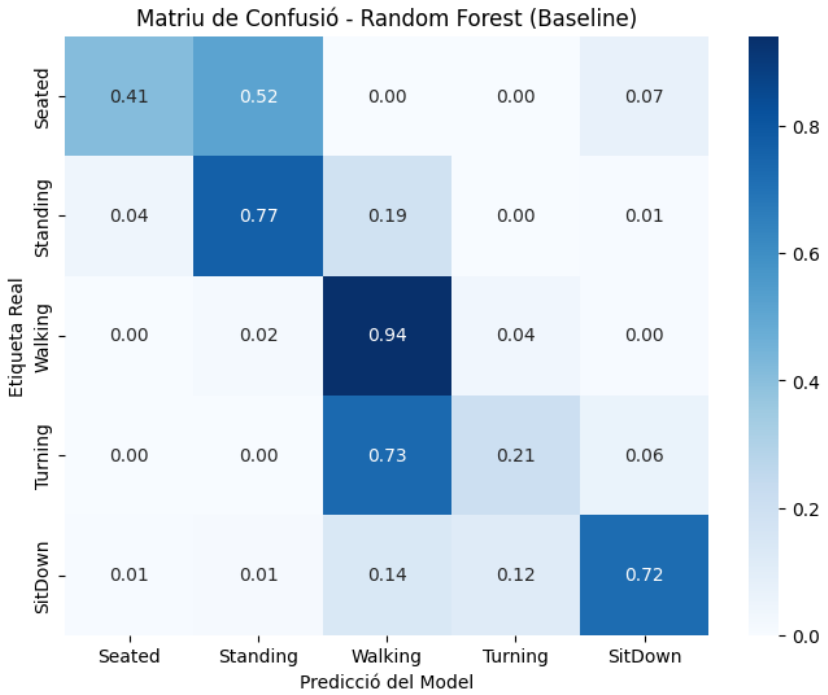

Figura 4.1: Matriu de confusió normalitzada del model Random Forest. S'observa una incapacitat sistemàtica per distingir activitats amb estadístics similars però dinàmiques temporals oposades.

L'anàlisi de la matriu de confusió posa de manifest dues limitacions greus derivades d'haver eliminat la dimensió temporal:

- **La "Ceguesa" als Girs (Turning → Walking):** És l'error més crític: el model classifica erròniament el **73%** dels girs com a "Caminar". Això es produeix perquè els estadístics globals (mitjana, desviació) d'un gir són gairebé idèntics als de la marxa recta. Sense accés a la seqüència temporal, el model és incapaç de detectar la variació progressiva en l'orientació que defineix el gir.
- **Confusió Estàtica (Seated vs Standing):** El model falla en distingir postures de repòs, classificant incorrectament el **52%** dels casos de "Seated" com a "Standing". En ambdós estats l'acceleració és constant (només actua la gravetat) i, mancant informació contextual, el classificador depèn de subtils diferències en l'angle del dispositiu que no són generalitzables entre usuaris.

En resum, els resultats evidencien que el Random Forest és molt ràpid, però aquesta

velocitat té un preu: no és prou precís per a les activitats complexes degut a que hem perdut la temporalitat. Per això, és necessari passar a models com les CNN o les LSTM, que són capaços d'analitzar la seqüència completa sense perdre detall.

4.2 Anàlisi de l'Arquitectura CNN

En aquest segon experiment, s'avalua la capacitat de la xarxa neuronal convolucional per extreure característiques de forma automàtica, sense intervenció manual.

4.2.1 Rendiment Global: El Dilema de la Localitat

Els resultats globals mostren una exactitud mitjana del **75.75%**. A primera vista, aquest resultat sembla contraintuïtiu, ja que és lleugerament inferior al Baseline (78.90%). Tanmateix, una anàlisi detallada per classes (Taula 4.2) revela un comportament molt diferent:

- **Millora en la Sensibilitat de Classes Difícils:** Mentre que el Random Forest era pràcticament cec als girs, la CNN comença a detectar-los. El *Recall* de la classe *Turning* ha pujat al **35%** (respecte al 21% del RF). Tot i ser encara insuficient, demostra que els filtres convolucionals són capaços de detectar certs patrons de rotació que els estadístics globals ignoraven.
- **Pèrdua d'Estabilitat Global:** La lleugera davallada en l'accuracy general s'explica per la naturalesa local de la CNN. En utilitzar filtres petits ($k = 3$), la xarxa és molt sensible a "micro-moviments"però manca de visió de conjunt. Això genera més falsos positius en classes tranquil·les si hi ha soroll al sensor.

Classe	Precision	Recall (Sensibilitat)	F1-Score	Suport
SEATED	62.00%	61.00%	61.00%	56
STANDING UP	76.00%	76.00%	76.00%	171
WALKING	83.00%	**85.00%**	**84.00%**	1061
TURNING	35.00%	35.00%	35.00%	233
SITTING DOWN	86.00%	72.00%	78.00%	162
Global (Avg)	69.00%	66.00%	67.00%	1683

Taula 4.2: Informe de classificació detallat per a la CNN. Destaquen l'alt rendiment en Walking i la persistent dificultat en Turning.

4.2.2 Matriu de Confusió i Límits de la Convolució

La Figura 4.2 mostra la distribució d'errors. Visualment, s'observa una millora en la definició de la diagonal respecte al Random Forest, però persisteixen confusions estructurals:

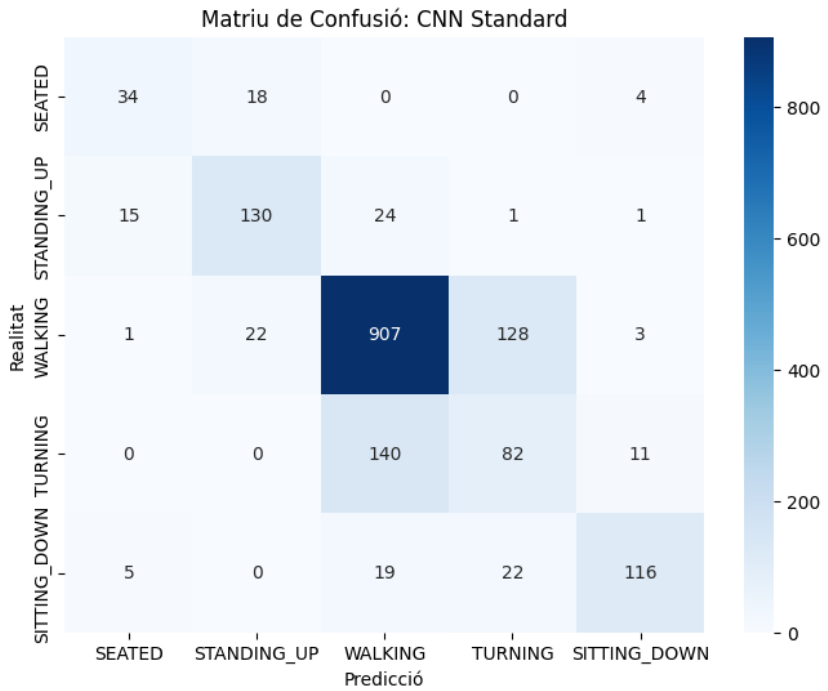

Figura 4.2: Matriu de confusió de la CNN Standard (valors absoluts). La classe Walking (907 encerts) segueix absorbint gran part dels errors de Turning (140 confusions).

- **El problema de la finestra lliscant:** De les 233 mostres reals de *Turning*, la xarxa en classifica 140 com a *Walking*. Això succeeix perquè, dins d'una finestra de 2.56 segons, un gir conté molts segments que s'assemblen a caminar (passos). Com que la CNN no té 'memòria', classifica els fragments com a passos normals.
- **Confusió Estàtica Persistent:** La classe *Seated* (34 encerts) encara té fuites cap a *Standing Up* (18 errors). Tot i que millora respecte al Baseline, confirma que l'acceleròmetre per si sol, sense analitzar la seqüència temporal d'entrada/sortida de la postura, és ambigu per a estats estàtics.

La CNN demostra ser superior al Baseline en l'extracció de detalls fins (millorant la detecció de girs i transicions), però el seu camp receptiu limitat li impedeix contextualitzar aquests detalls. Detecta "moviment de gir", però sovint el confon amb la variabilitat natural de caminar. Això evidencia la necessitat crítica d'incorporar un mecanisme de memòria a llarg termini (LSTM) per connectar aquests detalls en una seqüència coherent.

4.3 Anàlisi de l'Arquitectura Híbrida (DeepConvLSTM)

Finalment, s'avalua el model complet que combina l'extracció de característiques (CNN), la memòria seqüencial (LSTM) i l'estratègia de pesos manuals agressius per combatre el desbalanceig.

4.3.1 Rendiment Global i Robustesa

El model assoleix una exactitud mitjana del **80.82%**, convertint-se en la millor arquitectura de les tres estudiades. Més enllà de la mitjana, el més rellevant és la millora radical en la robustesa entre subjectes:

- **Recuperació de Casos Crítics:** Subjectes que eren problemàtics per als models anteriors han experimentat millores dràstiques. Per exemple, el Subjecte 10, que amb la CNN obtenia un resultat gairebé aleatori (58.90%), amb la LSTM puja fins al **86.30%**. Això suggereix que la memòria temporal permet al model "entendre"patrons de moviment atípics que els filtres estàtics no podien processar.
- **Nota sobre la Reproductibilitat:** Cal destacar que, a causa de la naturalesa estocàstica de la inicialització de pesos i de la divisió aleatòria del conjunt de validació (`GroupShuffleSplit`), els resultats exactes poden variar lleugerament ($\pm 1 - 2\%$) entre execucions. No obstant això, la tendència de millora respecte al Baseline es manté consistent.

4.3.2 Impacte dels Pesos Manuals: El cas del 'Turning'

L'aplicació de pesos de penalització (Turning $\times 3.5$, Walking $\times 0.9$) ha tingut l'efecte desitjat, tal com es desprèn de la Taula 4.3:

Classe	Precision	Recall (Sensibilitat)	F1-Score	Suport
SEATED	52.00%	**66.00%**	58.00%	56
STANDING UP	73.00%	74.00%	74.00%	171
WALKING	89.00%	89.00%	89.00%	1061
TURNING	54.00%	**50.00%**	**52.00%**	233
SITTING DOWN	81.00%	78.00%	79.00%	162
Global (Avg)	70.00%	71.00%	80.00%	1683

Taula 4.3: Informe de classificació de la DeepConvLSTM. La sensibilitat en Turning i Seated millora substancialment respecte als models anteriors.

- **Turning (L'Èxit Principal):** La sensibilitat (*Recall*) per als girs ha assolit el **50%**. Comparat amb el 21% del Random Forest i el 35% de la CNN, això suposa una millora del **138% respecte al Baseline**. La xarxa ha "après"a no ignorar els girs, gràcies al cost elevat que suposava fallar-los durant l'entrenament.
- **Manteniment del Walking:** Tot i haver reduït el pes de la classe *Walking* a 0.9, el seu encert es manté excel·lent (89%). Això valida l'estratègia: era possible "treure recursos"de la classe fàcil per donar-los a les difícils sense perjudicar el rendiment global.

4.3.3 Matriu de Confusió Final

La Figura 4.3 mostra la capacitat de discriminació final del sistema.

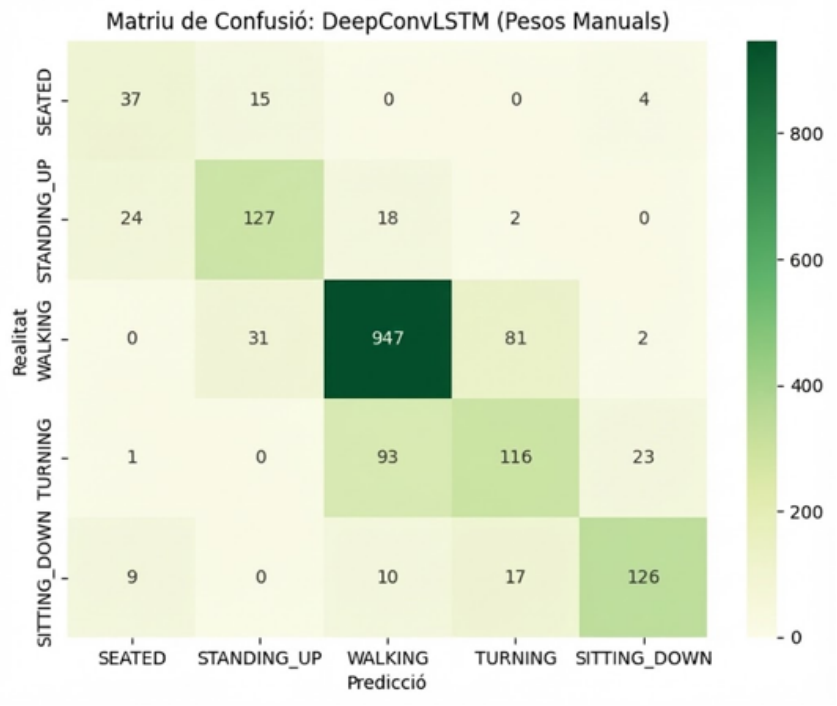

Figura 4.3: Matriu de confusió de la DeepConvLSTM (valors absoluts). Es redueix la dispersió en la classe Turning (116 encerts vs 82 de la CNN) i millora la distinció Seated/Standing.

S'observa com la confusió entre *Turning* i *Walking*, tot i persistir (93 errors), s'ha reduït significativament respecte als models anteriors. A més, la distinció entre estats estàtics (*Seated*) millora gràcies al context temporal, reduint els falsos positius cap a *Standing*.

4.4 Comparativa Global i Discussió

Per concloure l'anàlisi, la Taula 4.4 presenta una comparativa directa entre les tres aproximacions avaluades.

Els resultats confirmen que la combinació d'extracció automàtica de característiques (CNN) amb memòria a llarg termini (LSTM) i una estratègia de ponderació de costos és l'única via viable per reconèixer activitats complexes i transicions en un entorn desbalancejat.

	Sensibilitat per Classe (Recall)					
Model	**Seated**	**Stand Up**	**Walking**	**Turning**	**Sit Down**	**Acc. (LOSO)**
Baseline (RF)	41.00%	45.00%	**99.00%**	21.00%	55.00%	$78.90\% \pm 7.81\%$
CNN Standard	61.00%	**76.00%**	85.00%	35.00%	72.00%	$75.75\% \pm 9.98\%$
DeepConvLSTM	**66.00%**	74.00%	89.00%	**50.00%**	**78.00%**	$\mathbf{80.82\% \pm 6.92\%}$

Taula 4.4: Comparativa final del rendiment. La columna d'Accuracy (Acc.) inclou la mitjana i la desviació estàndard (±) del protocol LOSO. La DeepConvLSTM presenta la menor desviació (±6.92%), confirmant-se com el model més robust i estable entre diferents usuaris.

Capítol 5

Conclusions i treballs futurs

En aquest Treball Final de Màster s'ha abordat el repte del reconeixement d'activitats humanes (HAR) mitjançant sensors inercials, posant el focus en la problemàtica de la generalització entre usuaris (*cross-user*) i en la comparativa entre aproximacions clàssiques i arquitectures de *Deep Learning*. A continuació, es presenten les conclusions principals, una reflexió crítica sobre el procés i l'avaluació dels impactes generats.

5.1 Conclusions del treball

L'anàlisi experimental ha permès extreure tres conclusions fonamentals que responen a la pregunta de recerca plantejada:

(a) **Superioritat de l'Arquitectura Híbrida:** El model *DeepConvLSTM* ha demostrat ser l'arquitectura més robusta, assolint una exactitud global del **80.82%** i superant tant el *baseline* de Random Forest (78.90%) com la CNN estàndard (75.75%). Aquesta millora confirma la hipòtesi inicial que la combinació de convolucions i recurrència és necessària per capturar la complexitat del moviment humà.

(b) **Resultats en Transicions (Sorprenents vs. Esperats):** Un resultat que ha superat les expectatives inicials és la capacitat de recuperació de la classe *Turning* (Girar-se). S'esperava una millora respecte al *Random Forest*, però el salt qualitatiu ha estat sorprenent: la sensibilitat s'ha elevat del 0.21 al **0.50**. Aquest èxit no s'explica només per l'arquitectura: ha estat la sinergia entre la **memòria temporal (LSTM)**, que permet identificar la seqüència, i l'**estratègia de pesos manuals**, que ha forçat el model a prioritzar les classes minoritàries, el que ha permès corregir la 'ceguesa' estructural dels models clàssics.

(c) **Generalització Cross-User Assolida:** L'ús del protocol de validació *Leave-One-Subject-Out* (LOSO) certifica que els resultats són realistes. El fet que el model mantingui un rendiment superior al 80% predint sobre usuaris que mai ha vist durant l'entrenament valida que l'arquitectura aprèn patrons biomecànics universals, complint així l'objectiu principal de generalització.

5.2 Reflexió sobre l'assoliment dels objectius

A continuació, s'avalua el grau de compliment dels objectius definits a l'inici del treball:

- **Objectiu Principal (Assolit):** S'ha donat compliment a l'objectiu central identificant el model *DeepConvLSTM* com l'arquitectura de millor rendiment. L'enfocament en la capacitat de generalització s'ha validat satisfactòriament mitjançant el protocol *Leave-One-Subject-Out* (LOSO), demostrant que el model pot predir l'activitat d'usuaris desconeguts amb una exactitud superior al 80%.
- **Revisió d'estudis previs (Assolit):** L'estat de l'art ha permès identificar la tendència cap a models profunds i justificar l'elecció de l'arquitectura DeepConvLSTM.
- **Avaluació de models i protocols (Assolit):** S'han implementat i comparat tres famílies d'algorismes representatius: **Machine Learning clàssic** (Random Forest), **Deep Learning convolucional** (CNN) i **arquitectures híbrides** (DeepConvLSTM). Aquesta comparativa sota el protocol LOSO ha permès identificar clarament les limitacions dels models estàtics i la necessitat de combinar convolució i recurrència.
- **Anàlisi de l'estratègia de fusió (Assolit):** S'ha complert l'objectiu d'optimitzar una estratègia de *Early Fusion* eficient. Els resultats demostren que la integració de les dades de tots dos dispositius en un únic tensor d'entrada permet al model *DeepConvLSTM* assolir una precisió global elevada i una robustesa notable en la classificació de les activitats complexes.
- **Identificació de limitacions (Assolit):** S'ha detectat el desbalanceig sever de classes i s'hi ha donat resposta mitjançant estratègies de pesos manuals, documentant l'impacte positiu d'aquesta decisió.

5.3 Anàlisi del seguiment de la planificació

El desenvolupament del treball ha seguit majoritàriament l'estructura de fases (M1-M6) prevista. Tanmateix, s'ha produït una desviació rellevant a la fase M4 (Implementació), que ha requerit un esforç superior al planificat. La complexitat de configurar el bucle d'entrenament personalitzat per al protocol LOSO (entrenar 23 models independents) ha estat elevada.

Canvis introduïts: Per garantir l'èxit del treball davant d'aquesta càrrega tècnica, es va decidir sacrificar la recollida de dades pròpies (prevista inicialment a M3/M4) per dedicar tots els recursos a perfeccionar l'entrenament sobre el dataset públic. Aquesta decisió metodològica ha estat adequada, ja que ha permès obtenir uns resultats estadísticament més sòlids i rigorosos que els que s'haurien obtingut amb un dataset propi petit i poc validat.

5.4 Avaluació de l'impacte

En relació als impactes previstos a la secció 1.3:

- **Ètic i Social (Assolit):** L'objectiu de contribuir al benestar s'alinea amb els resultats. El model funciona amb sensors de baix cost, confirmant la **viabilitat d'implementar solucions de salut a gran escala sense necessitat d'equipament mèdic dedicat**. L'ús exclusiu de dades anonimitzades ha mitigat totalment els riscos de privacitat previstos. No s'han detectat impactes negatius no previstos en aquesta àrea.
- **Sostenibilitat (Mitigat):** L'impacte negatiu del consum energètic de les GPU (previst a 1.3.1) s'ha mitigat activament mitjançant la implementació de l'*Early Stopping*, que ha evitat cicles de còmput innecessaris un cop el model convergia.
- **Diversitat (Assolit):** Tal com es plantejava a l'apartat 1.3.3, el treball ha aprofitat l'heterogeneïtat del dataset (gèneres i complexions físiques diverses) per garantir que el model no estigui esbiaixat cap a un perfil físic concret. Això assegura que la solució tecnològica proposada és inclusiva i aplicable a un rang ampli de la població adulta.

5.5 Línies de treball futur

Finalment, s'identifiquen diverses vies per continuar aquesta recerca que han quedat pendents:

- **Implementació en Temps Real:** Portar el model *DeepConvLSTM* entrenat a una aplicació mòbil per validar-ne el rendiment (latència i bateria) en un entorn d'execució real.
- **Ampliació Demogràfica:** El dataset actual no inclou persones majors de 70 anys. És imprescindible validar el model amb aquesta població específica per confirmar la seva utilitat en l'assistència geriàtrica.
- **Mecanismes d'Atenció:** Explorar arquitectures basades en *Transformers* per permetre al model ponderar automàticament la importància de cada sensor segons l'activitat.
- **Validació Cross-Dataset:** Tot i que s'ha garantit la generalització entre usuaris mitjançant el protocol LOSO, seria interessant avaluar la robustesa del model aplicant-lo directament sobre altres conjunts de dades públics (com ara *WISDM* o *MotionSense*). Això permetria mesurar la resistència del sistema davant canvis de hardware (sensors diferents) i protocols de gravació, un repte conegut com a *generalització de domini*.

Capítol 6

Glossari

Accuracy (Exactitud): Mètrica d'avaluació que mesura el percentatge total de prediccions correctes realitzades pel model respecte al total de mostres analitzades.

Baseline: Model de referència, generalment més simple, utilitzat per establir un punt de partida i quantificar les millores aportades per models més complexos. En aquest treball, el *Random Forest* actua com a *baseline*.

Batch Normalization: Tècnica utilitzada en xarxes neuronals per normalitzar les entrades de cada capa, estabilitzant el procés d'aprenentatge i accelerant la convergència.

CNN (Convolutional Neural Network): Xarxa Neuronal Convolucional. Tipus d'arquitectura de *Deep Learning* especialitzada en l'extracció automàtica de característiques locals mitjançant l'aplicació de filtres o *kernels*.

Cross-User (Generalització entre usuaris): Capacitat d'un model per reconèixer correctament l'activitat d'un usuari nou que no ha format part del conjunt de dades d'entrenament.

Data Augmentation: Tècnica per incrementar artificialment la mida del conjunt d'entrenament generant noves mostres modificades (per exemple, afegint soroll gaussià) a partir de les originals, amb l'objectiu de reduir l'*overfitting*.

Dropout: Tècnica de regularització que consisteix a desactivar aleatòriament un percentatge de neurones durant l'entrenament per evitar que la xarxa depengui excessivament de camins específics, millorant així la generalització.

Early Fusion (Fusió Primerenca): Estratègia de fusió de sensors on les dades de diferents fonts (ex: mòbil i rellotge) es combinen al principi del procés, creant un únic vector o tensor d'entrada per al model.

Epoch (Època): Un cicle complet durant el qual l'algorisme d'aprenentatge veu tot el conjunt de dades d'entrenament una vegada.

F1-Score: Mètrica que combina la *Precision* i el *Recall* en un sol valor mitjançant la seva mitjana harmònica. És especialment útil en datasets desbalancejats.

GAP (Global Average Pooling): Operació que calcula la mitjana de cada mapa de característiques complet, reduint dràsticament la dimensió dels tensors i els paràmetres del model abans de la classificació final.

HAR (Human Activity Recognition): Reconeixement d'Activitat Humana. Àrea de recerca centrada en la identificació automàtica d'accions físiques a partir de dades de sensors.

LOSO (Leave-One-Subject-Out): Protocol de validació creuada on, en cada iteració, es reserva un subjecte complet per al test i s'entrena amb la resta. És l'estàndard per avaluar la generalització *cross-user*.

LSTM (Long Short-Term Memory): Tipus de xarxa neuronal recurrent (RNN) capaç d'aprendre dependències a llarg termini en dades seqüencials, solucionant el problema de l'esvaniment del gradient de les RNN clàssiques.

Overfitting (Sobreajustament): Fenomen on un model aprèn "de memòria"el soroll o detalls específics de les dades d'entrenament, perdent la capacitat de generalitzar a dades noves.

Recall (Sensibilitat): Mètrica que mesura la capacitat del model per detectar correctament totes les instàncies positives d'una classe específica.

RNN (Recurrent Neural Network): Xarxa Neuronal Recurrent. Arquitectura dissenyada per processar seqüències de dades, on la sortida d'un pas anterior s'utilitza com a entrada per al pas següent.

Sensor Fusion: Procés de combinar dades de múltiples sensors per obtenir una informació més precisa i robusta que la que proporcionaria qualsevol dels sensors per separat.

Softmax: Funció d'activació utilitzada habitualment en la capa de sortida de classificadors multi-classe per convertir valors numèrics bruts en una distribució de probabilitats.

Bibliografia

[1] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, Jorge Luis Reyes-Ortiz, et al. A public domain dataset for human activity recognition using smartphones. In *Esann*, volume 3, pages 3–4, 2013.

[2] Muhammad Haseeb Arshad, Muhammad Bilal, and Abdullah Gani. Human activity recognition: Review, taxonomy and open challenges. *Sensors*, 22(17):6463, 2022.

[3] Akram Bayat, Marc Pomplun, and Duc A Tran. A study on human activity recognition using accelerometer data from smartphones. *Procedia Computer Science*, 34:450–457, 2014.

[4] Avijoy Chakma, Abu Zaher Md Faridee, Indrajeet Ghosh, and Nirmalya Roy. Domain adaptation for inertial measurement unit-based human activity recognition: A survey. *arXiv preprint arXiv:2304.06489*, 2023.

[5] Ian Cleland, Basel Kikhia, Chris Nugent, Andrey Boytsov, Josef Hallberg, Kåre Synnes, Sally McClean, and Dewar Finlay. Optimal placement of accelerometers for the detection of everyday activities. *Sensors*, 13(7):9183–9200, 2013.

[6] Florenc Demrozi, Graziano Pravadelli, Azra Bihorac, and Parisa Rashidi. Human activity recognition using inertial, physiological and environmental sensors: A comprehensive survey. *IEEE access*, 8:210816–210836, 2020.

[7] Vincenzo Dentamaro, Vincenzo Gattulli, Donato Impedovo, and Fabio Manca. Human activity recognition with smartphone-integrated sensors: A survey. *Expert Systems with Applications*, 246:123143, 2024.

[8] Andrey D Ignatov and Vadim V Strijov. Human activity recognition using quasi-periodic time series collected from a single tri-axial accelerometer. *Multimedia tools and applications*, 75(12):7257–7270, 2016.

[9] Miguel Matey-Sanz. Smartphone and smartwatch inertial measurements from heterogeneous subjects for human activity recognition., October 2023. https://doi.org/10.5281/zenodo.8398688.

[10] Miguel Matey-Sanz, Sven Casteleyn, and Carlos Granell. Dataset of inertial measurements of smartphones and smartwatches for human activity recognition. *Data in Brief*, 51:109809, 2023.

[11] Sakorn Mekruksavanich and Anuchit Jitpattanakul. Device position-independent human activity recognition with wearable sensors using deep neural networks. *Applied Sciences*, 14(5):2107, 2024.

[12] Otávio Napoli, Dami Duarte, Patrick Alves, Darlinne Hubert Palo Soto, Henrique Evangelista de Oliveira, Anderson Rocha, Levy Boccato, and Edson Borin. A benchmark for domain adaptation and generalization in smartphone-based human activity recognition. *Scientific Data*, 11(1):1192, 2024.

[13] Farhad Nazari, Navid Mohajer, Darius Nahavandi, Abbas Khosravi, and Saeid Nahavandi. Comparison study of inertial sensor signal combination for human activity recognition based on convolutional neural networks. In *2022 15th International conference on human system interaction (HSI)*, pages 1–6. IEEE, 2022.

[14] Francisco Javier Ordóñez and Daniel Roggen. Deep convolutional and lstm recurrent neural networks for multimodal wearable activity recognition. *Sensors*, 16(1):115, 2016.

[15] World Health Organization. *World report on ageing and health*. World Health Organization, 2015.

[16] Thais Mayumi Oshiro, Pedro Santoro Perez, and José Augusto Baranauskas. How many trees in a random forest? In *MLDM*, pages 154–168. Springer, 2012.

[17] Jianbo Yang, Minh Nhut Nguyen, Phyo Phyo San, Xiaoli Li, Shonali Krishnaswamy, et al. Deep convolutional neural networks on multichannel time series for human activity recognition. In *Ijcai*, volume 15, pages 3995–4001. Buenos Aires, Argentina, 2015.

[18] Xiaozhou Ye, Waleed H Abdulla, Nirmal Nair, and Kevin I-Kai Wang. Cross-user activity recognition using deep domain adaptation with temporal relation information. *arXiv preprint arXiv:2403.15424*, 2024.