UOC Universitat Oberta
de Catalunya

# Avaluació d'arquitectures de Deep Learning per al Reconeixement d'Activitats Humanes (HAR) mitjançant sensors inercials

Màster en Ciència de Dades

**Gerard Vidal Casasayas**

Gener 2025

**Consultor**: Joaquín Torres Sospedra
**PRA**: David Masip Rodo
*Pattern Recognition and Computer Vision in Applied Sciences*

# Context: L'Envelliment i l'Autonomia

## El repte demogràfic

L'any 2050, més de 2.000 milions de persones tindran més de 60 anys (OMS).

## Necessitat d'autonomia

Viure a casa de manera independent requereix sistemes de seguretat passiva.

## La solució 'Wearable'

Aprofitar els sensors (acceleròmetres) que ja portem al rellotge i al mòbil.

# El Repte: La Generalització (Cross-User)

## La realitat biomètrica

Cada persona té una 'signatura' de moviment única.

Variables crítiques: Alçada, pes, edat, cadència de pas.

Els models clàssics tendeixen a l'Overfitting (memoritzen l'usuari).

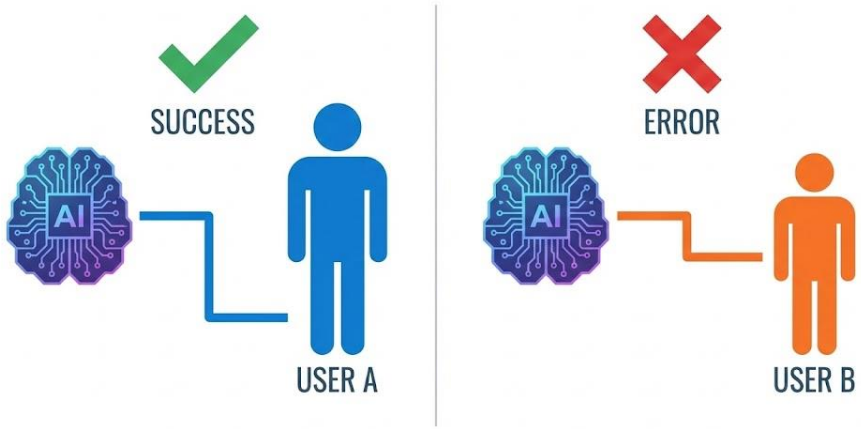


OBJECTIU DEL TFM

**Crear un model que generalitzi correctament sense necessitat de calibratge individual.**

# Metodologia: Dades i Sensors

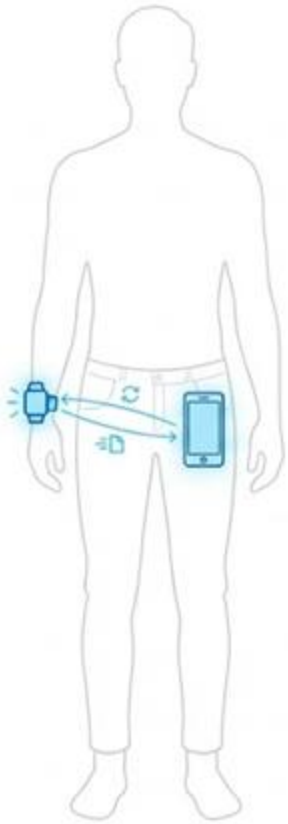

**Dataset Públic:** Matey-Sanz et al. (Zenodo).

**Mostra:** 23 Subjectes heterogenis (Gènere/Edat/Pes/Alçada).

**Sensor Fusion:** Smartphone (Butxaca) + Smartwatch (Canell).

**Dades:** Acceleròmetre + Giroscopi a 100 Hz.

| x_acc | y_acc | z_acc | x_gyro | y_gyro | z_gyro | timestamp | label |
|---|---|---|---|---|---|---|---|
| -4.1602 | -1.1829 | -8.9907 | 0.0028 | -0.0139 | -0.0321 | 1657533977813 | SEATED |
| -4.1841 | -1.1901 | -9.0146 | 0.0071 | -0.0114 | -0.0229 | 1657533977864 | SEATED |
| -4.1961 | -1.2308 | -9.0505 | 0.0101 | -0.0126 | -0.0125 | 1657533977864 | SEATED |
| -4.2442 | -1.2547 | -9.1055 | 0.0113 | -0.0139 | -0.0003 | 1657533977865 | SEATED |
| -4.2323 | -1.2882 | -9.1534 | 0.0113 | -0.0169 | 0.0131 | 1657533977865 | SEATED |
| ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |

*Fragment real de les dades d'entrada (Raw Data)*

# Evolució: De l'Estadística al Deep Learning

## 1. Baseline: Random Forest

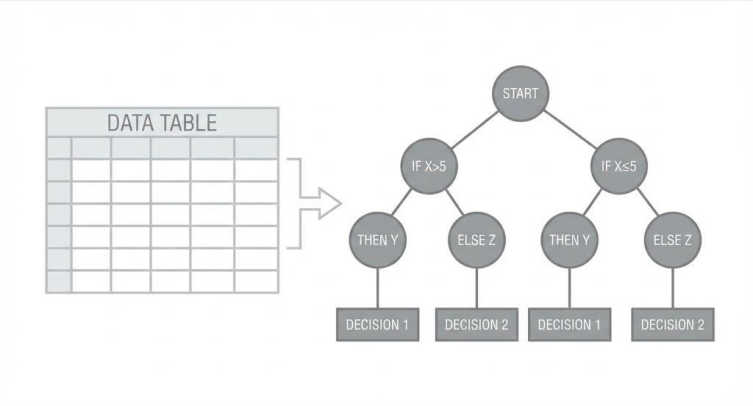


- Feature Engineering Manual.
- Calcula estadístics globals (Mitjana, Max, Min).
- Perd la dimensió temporal (No sap l'ordre).

## 2. Proposta: DeepConvLSTM

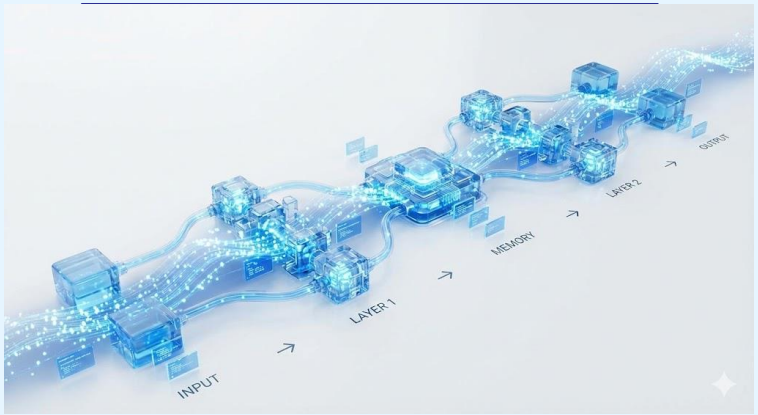


- **Aprenentatge End-to-End (Raw Data).**
- **CNN: Extreu característiques automàticament.**
- **LSTM: Recorda la seqüència (Context).**

# Disseny de l'Arquitectura Híbrida (DeepConvLSTM)

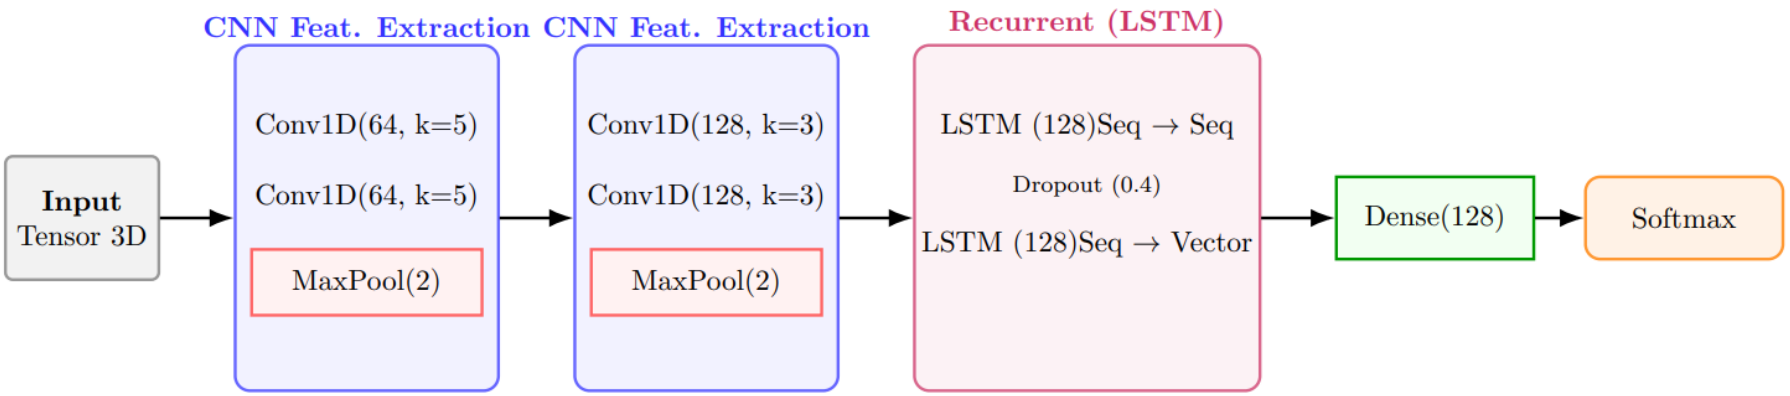


## 1. Bloc CNN (Extracció)

Les primeres capes actuen com a filtres. Detecten patrons locals i formes en el senyal brut (feature extraction).

## 2. Bloc LSTM (Memòria)

Processa la seqüència temporal. Entén l'ordre dels fets ('Abans estava dret, ara està assegut').

**Optimització: Ús de 'Class Weights' per penalitzar errors en girs.**

# Validació Rigorosa: Protocol LOSO

## Leave-One-Subject-Out

- Simulació real: El model s'enfronta a un usuari que MAI ha vist.
- Evitem el 'Data Leakage': Dades d'entrenament i test totalment aïllades.
- Robustesa estadística: Repetim l'experiment 23 vegades (una per cada subjecte).

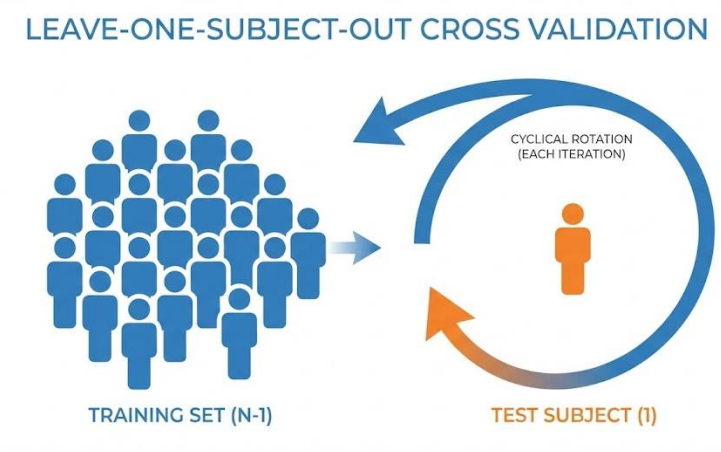


**Iteració k: Entrenar amb 22 -> Testejar amb 1**

# Resultats Baseline: La Ceguesa als Girs

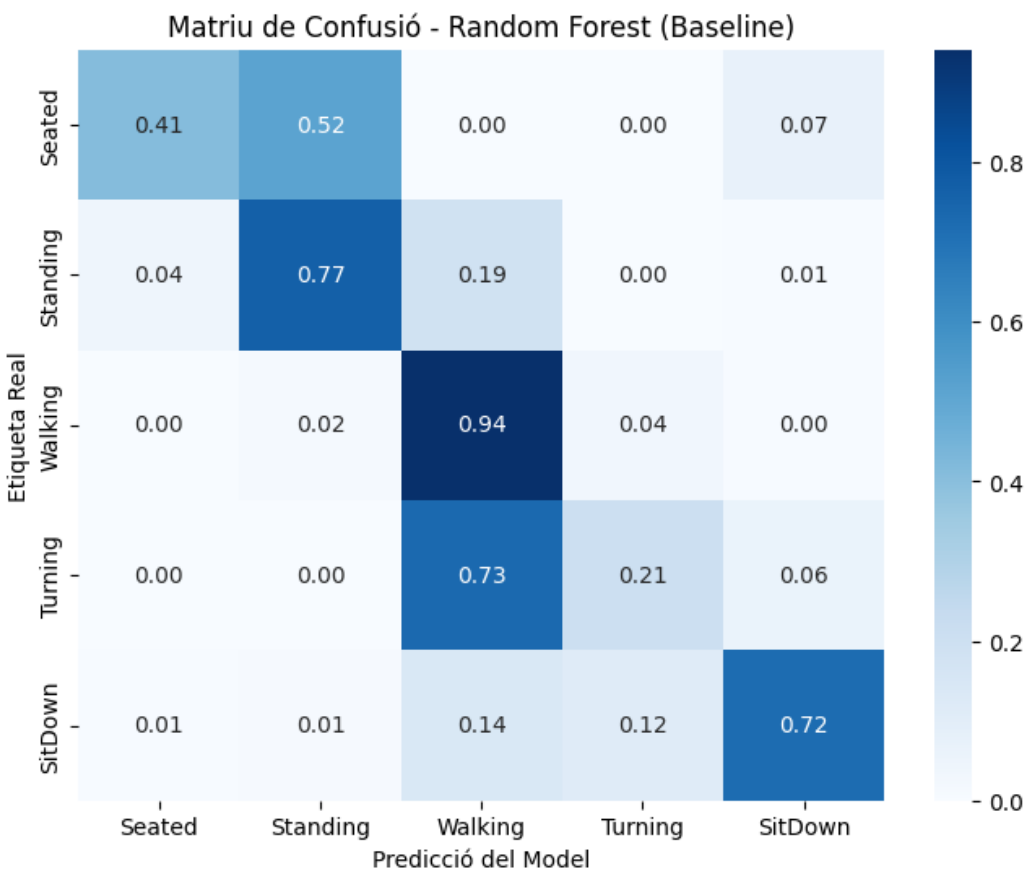


## Anàlisi del Fracàs

- **Accuracy Global Enganyosa: El 79% sembla acceptable, però amaga problemes greus.**

### 1. Error Crític en Girs:

El model classifica erròniament el 73% dels girs com a 'Caminar'.

### 2. Confusió Estàtica:

52% de confusions entre 'Seated' i 'Standing' (només actua la gravetat).

### 3. La Causa:

Estadísticament són idèntics. Sense dimensió temporal, el model és cec a la rotació progressiva.

# Resultats DL: La Recuperació del Context

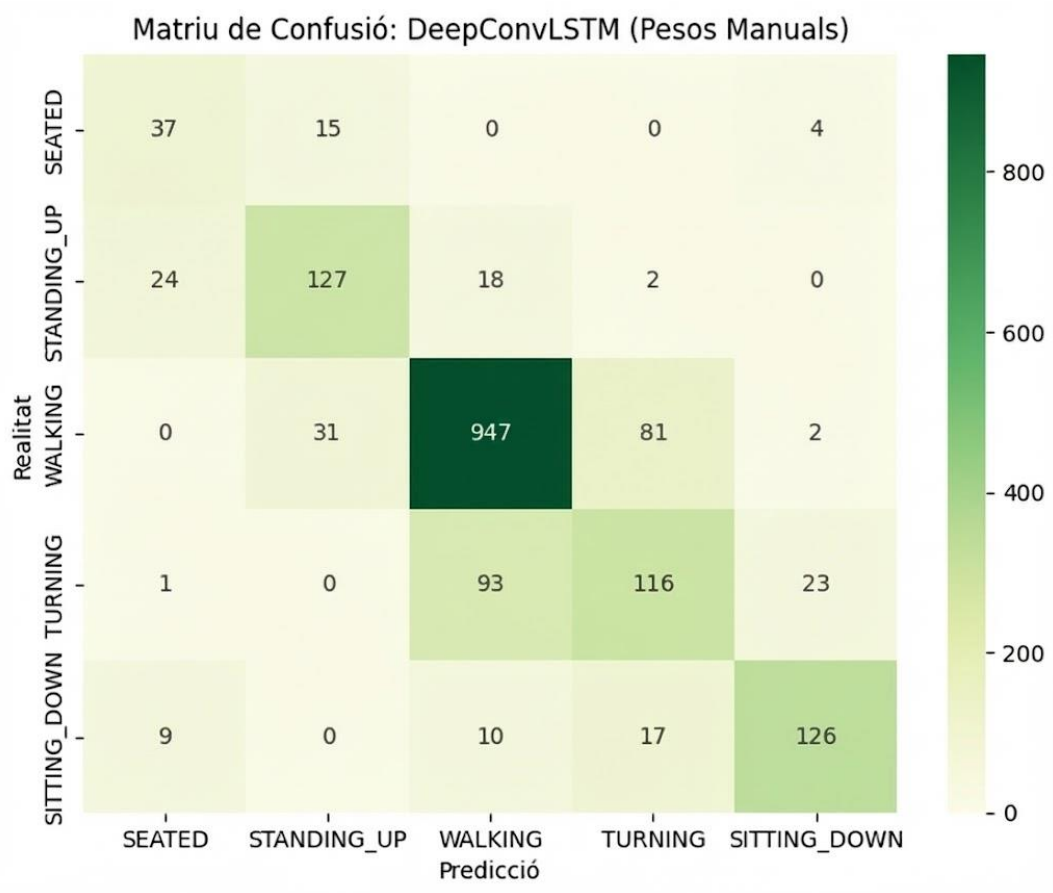


## Impacte de l'arquitectura

**Accuracy Global: 80.82%**

### 1. Hem duplicat la detecció de girs:

Gràcies a la memòria LSTM i els Class Weights, hem passat de 'no veure'ls' a detectar-ne la majoria rellevant.

### 2. Correcció de la Marxa:

La confusió Walking-Turning s'ha reduït dràsticament. El model entén que un gir és una seqüència, no una passa estranya.

### 3. Robustesa (LOSO):

Aquests resultats són en usuaris NOUS. El sistema és viable per a un producte real 'Plug & Play'.

# Conclusions i Treball Futur

## Fites Assolides

**✓ Superioritat Híbrida (80.8%)**
DeepConvLSTM supera el Random Forest i la CNN estàndard. La complexitat addicional està justificada.

**✓ Èxit en Transicions (x2.5)**
Recall de 0.21 a 0.50 en Girs. La LSTM + Class Weights han curat la 'ceguesa'.

**✓ Generalització Real (LOSO)**
Validat: el sistema funciona amb usuaris nous (Objectiu Cross-User assolit).

## Properes Passes

**Temps Real (App)**
Portar el model al mòbil per validar latència i bateria en entorn real.

**Ampliació Demogràfica (>70 anys)**
Validar amb el target real de risc de caigudes (actualment absents al dataset).

**Noves Arquitectures**
Explorar Transformers (Atenció) i validació Cross-Dataset.

# Moltes gràcies per la vostra atenció

**Gerard Vidal Casasayas**
Màster en Ciència de Dades - UOC